



Kemenkeu  
Corporate University



# PJJ Data Analytics 2026

## Data Preparation

Riki Akbar  
Ibrahim Saleh Siregar

# Kenalan Dulu



**Riki Akbar**  
DJSEF



**Ibrahim Saleh Siregar**  
DJP



# Sebelum Lanjut, Kita Pop Quiz Dulu

Join at [menti.com](https://menti.com) | use code **8460 9642**

# Data Preparation

## Ingat CRISP-DM?

Business Understanding	Data Understanding	Data Preparation	Modeling	Evaluation	Deployment
<p><b>Determine Business Objectives</b> <i>Background</i> <i>Business Objectives</i> <i>Business Success Criteria</i></p> <p><b>Assess Situation</b> <i>Inventory of Resources Requirements, Assumptions, and Constraints</i> <i>Risks and Contingencies</i> <i>Terminology</i> <i>Costs and Benefits</i></p> <p><b>Determine Data Mining Goals</b> <i>Data Mining Goals</i> <i>Data Mining Success Criteria</i></p> <p><b>Produce Project Plan</b> <i>Project Plan</i> <i>Initial Assessment of Tools and Techniques</i></p>	<p><b>Collect Initial Data</b> <i>Initial Data Collection Report</i></p> <p><b>Describe Data</b> <i>Data Description Report</i></p> <p><b>Explore Data</b> <i>Data Exploration Report</i></p> <p><b>Verify Data Quality</b> <i>Data Quality Report</i></p>	<p><b>Select Data</b> <i>Rationale for Inclusion/Exclusion</i></p> <p><b>Clean Data</b> <i>Data Cleaning Report</i></p> <p><b>Construct Data</b> <i>Derived Attributes</i> <i>Generated Records</i></p> <p><b>Integrate Data</b> <i>Merged Data</i></p> <p><b>Format Data</b> <i>Reformatted Data</i></p> <p><b>Dataset</b> <i>Dataset Description</i></p>	<p><b>Select Modeling Techniques</b> <i>Modeling Technique</i> <i>Modeling Assumptions</i></p> <p><b>Generate Test Design</b> <i>Test Design</i></p> <p><b>Build Model</b> <i>Parameter Settings</i> <i>Models</i> <i>Model Descriptions</i></p> <p><b>Assess Model</b> <i>Model Assessment</i> <i>Revised Parameter Settings</i></p>	<p><b>Evaluate Results</b> <i>Assessment of Data Mining Results w.r.t. Business Success Criteria</i> <i>Approved Models</i></p> <p><b>Review Process</b> <i>Review of Process</i></p> <p><b>Determine Next Steps</b> <i>List of Possible Actions</i> <i>Decision</i></p>	<p><b>Plan Deployment</b> <i>Deployment Plan</i></p> <p><b>Plan Monitoring and Maintenance</b> <i>Monitoring and Maintenance Plan</i></p> <p><b>Produce Final Report</b> <i>Final Report</i> <i>Final Presentation</i></p> <p><b>Review Project</b> <i>Experience Documentation</i></p>

# Kenapa Data Harus di-*prepare*?

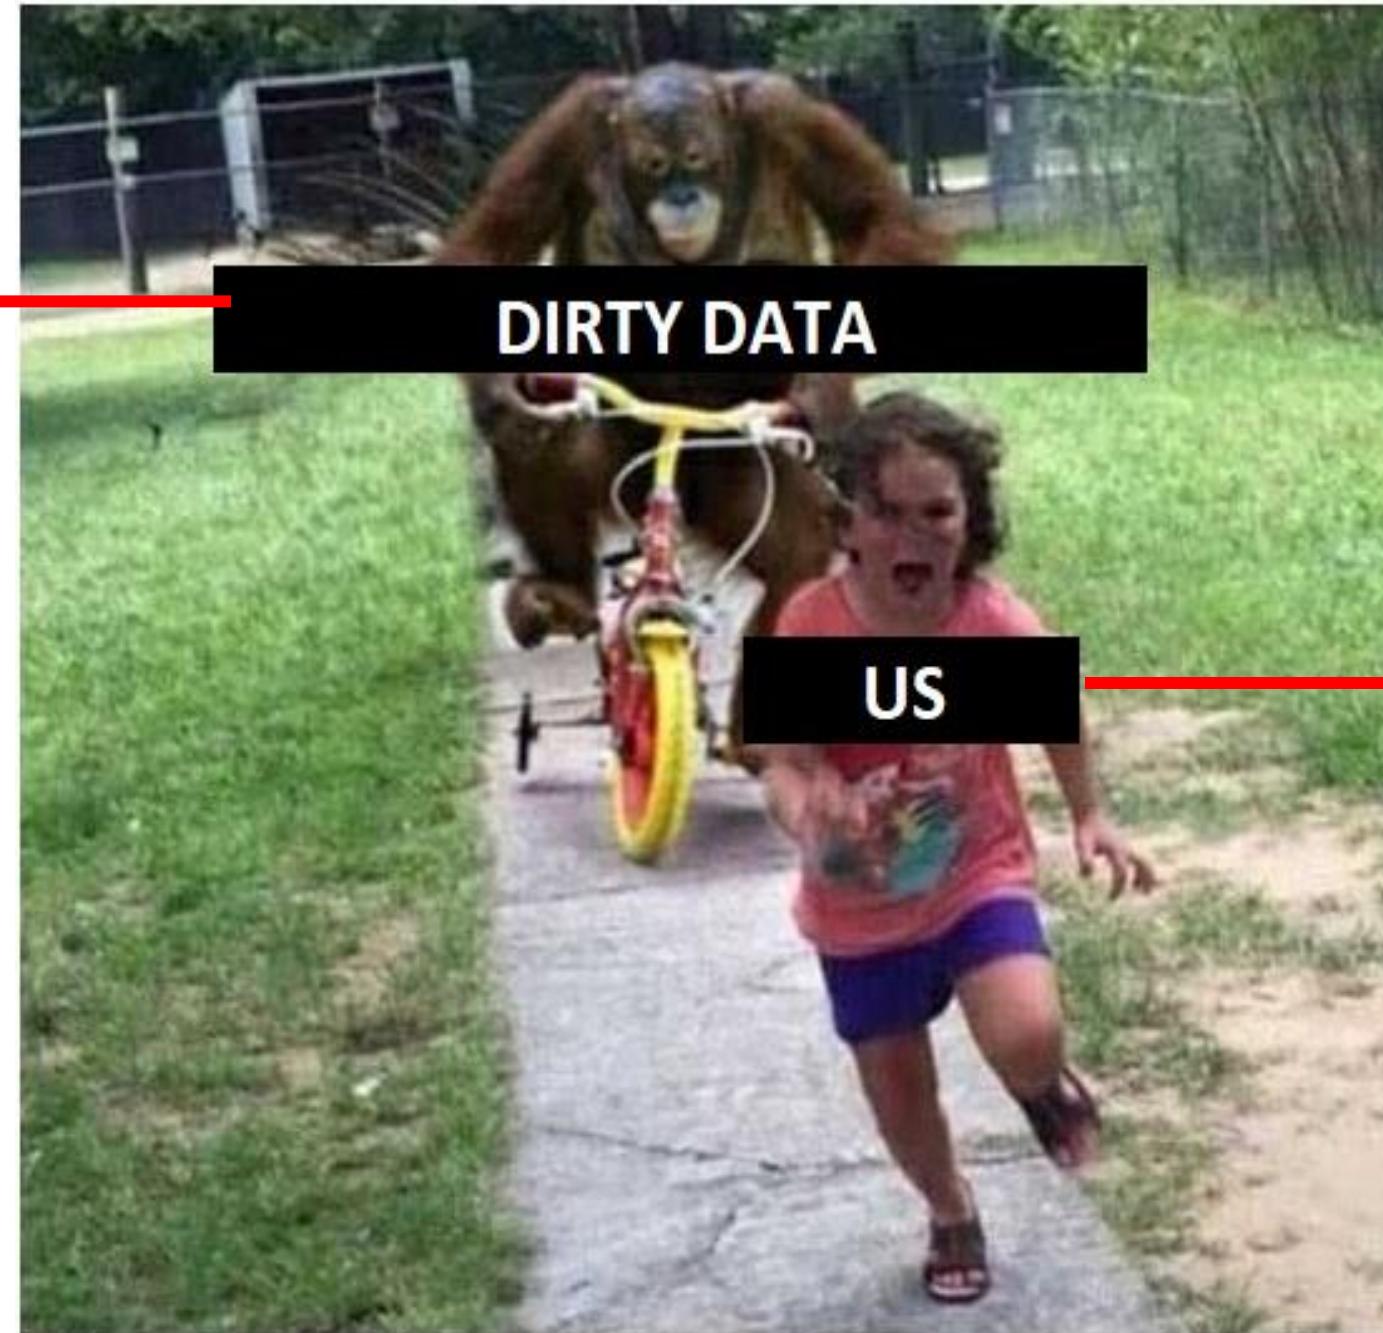
## Data tidak selalu 100% berkualitas

### Data Quality Issues

- Ada beberapa atribut yang nilainya kosong (**missing values**)
- Ada beberapa baris data yang duplikat (**duplicates**)
- Beberapa nilai atribut data terlihat seperti anomali (**outliers & noises**)
- Beberapa atribut bisa jadi diformat secara tidak tepat (**formatting errors**)

### Analysis Perspective

- Ingat Garbage-in, Garbage-out
- Pada tahap analisis dan pengembangan model, kita (boleh jadi) membutuhkan **lebih banyak atribut** (turunan)
- Atau bahkan, beberapa atribut **malah tidak relevan** dalam analisis



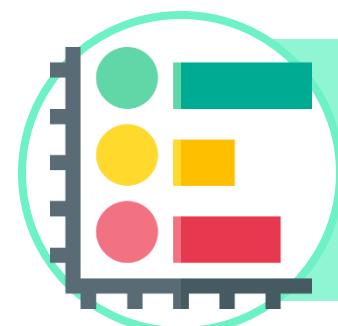
# So, Apa Target Mata Pelatihan Data Preparation?



**Mampu mengenali Data Quality Issues**



**Mampu melakukan transformasi data numerik**



**Mampu melakukan transformasi data kategorikal**



**Mampu melakukan transformasi data tekstual**

# Data: Berdasarkan Bentuknya

## Unstructured data

The university has 5600 students. John's ID is number 1, he is 18 years old and already holds a B.Sc. degree. David's ID is number 2, he is 31 years old and holds a Ph.D. degree. Robert's ID is number 3, he is 51 years old and also holds the same degree as David, a Ph.D. degree.

- Tidak ada struktur
- Teks, Audio, File biner, dll

## Semi-structured data

```
<University>
  <Student ID="1">
    <Name>John</Name>
    <Age>18</Age>
    <Degree>B.Sc.</Degree>
  </Student>
  <Student ID="2">
    <Name>David</Name>
    <Age>31</Age>
    <Degree>Ph.D.</Degree>
  </Student>
  ...
</University>
```

Key      Value

## Structured data

ID	Name	Age	Degree
1	John	18	B.Sc.
2	David	31	Ph.D.
3	Robert	51	Ph.D.
4	Rick	26	M.Sc.
5	Michael	19	B.Sc.

Baris

Kolom/Atribut /Fitur

- Diorganisasikan melalui baris-kolom
- Rigid, cocok untuk tujuan penyimpanan data
- RDBMS e.g., MySQL, Postgre, etc

# Data: Berdasarkan Tipenya



# Data Quality Issues



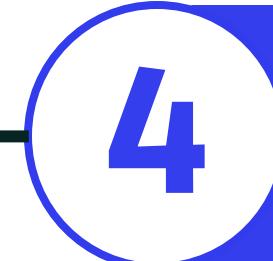
**Duplicates**



**Outliers & Noises**



**Missing Values**



**Formatting Errors**

# Data Quality Issues: Duplicates

Apakah baris data ini dapat kita golongkan sebagai baris data duplikat?

```
1 df[df['name'].duplicated(keep=False)].sort_values("name", ascending=True)
```

		name	rating	genre	year	released	score
283		A Nightmare on Elm Street	R	Horror	1984	November 16, 1984 (United States)	7.5
3920		A Nightmare on Elm Street	R	Crime	2010	April 30, 2010 (United States)	5.2
5334		Aladdin	PG	Adventure	2019	May 24, 2019 (United States)	6.9
1171		Aladdin	G	Animation	1992	November 25, 1992 (United States)	8.0

Mengapa kita perlu menghapus baris data duplikat?

Mengidentifikasi lebih dari satu baris data identik berdasarkan **kriteria duplikasi yang ditentukan**

Hapus duplikat

```
df.drop_duplicates(subset=['name', 'year'], inplace=True)
```

# Data Quality Issues: Outliers and Noises

Seringkali kita kesulitan membedakan noises dengan outliers  
**Jadi, yang mana outliers? yang mana noises?**

Student Name	Grade
Mark	98
Ruffalo	4
Denzel	87
Washington	64
Benedict	75
Cumberbatch	81

## Outliers

Baris data yang mengandung nilai ekstrem.

Student Name	Grade
Mark	98
Ruffalo	Cat
Denzel	87
Washington	64
Benedict	75
Cumberbatch	81

## Noises

“Unwanted variability” (Kahneman et al.)  
Baris data yang **tidak** seharusnya **berada dalam kelompok/distribusi data/dataset**

# Data Quality Issues: Outliers and Noises

## Diskusi

Diketahui nilai yang diberikan kepada para peserta pelatihan harus berada dalam interval 70-90

Student Name	Grade
Mark	98
Ruffalo	4
Denzel	87
Washington	64
Benedict	75
Cumberbatch	81

Outlier? atau Noise?

Outlier? atau Noise?

# Data Quality Issues: Mengidentifikasi Outliers

## Z-score

Mengukur sejauh apa sebuah data point terdeviasi dari rata-rata kelompok data

$$Z = \frac{x - \text{mean}}{\text{std}}$$

## Outliers menggunakan Z-score

Outliers jika:

Z-score > 3 atau

Z-score < -3

## Jarak Antar-Kuartil/Inter-Quartile Range (IQR)

Mengukur sebaran data

$$IQR = Q_3 - Q_1$$

## Outliers menggunakan IQR

Outliers jika:

$x > Q_3 + 1.5 * IQR$  atau

$x < Q_1 - 1.5 * IQR$

# Data Quality Issues : How to Handle Outliers?

Statistik hanya memberikan sinyal, bukan keputusan.

Keputusan untuk menghapus atau tidak menghapus outlier **sangat bergantung pada Business Understanding dan Data Understanding**, nilai ekstrem bisa jadi sampah (*noise*) atau justru "emas" (*golden nugget/anomaly*) bagi bisnis.

- Tindakan untuk *Noises*
  - *Removal*
  - *Imputation*
- Tindakan untuk *Outliers*
  - *Keep & Analyze* (jangan dibuang)
  - Transformasi Data
  - Gunakan Model yang robust
  - Removal (jika kita memang yakin outliers tidak relevan dengan tujuan analisis)

# Data Quality Issues: Missing Values

		name	rating	genre
279	Nausicaä of the Valley of the Wind		NaN	Animation
1031	Y Tu Mamá También		NaN	Drama
1198	Madadayo		NaN	Drama
1229	Return of the Living Dead III		NaN	Horror
1259	Jason Goes to Hell: the Final Friday		NaN	Fantasy
1787	Happy Together		NaN	Drama
2175	Eyes Wide Shut		NaN	Drama
2246	Brother		NaN	Crime

Baris data dengan satu atau lebih kolom yang memuat missing value biasanya ditandai dengan nilai **NaN** atau **NULL**

How to handle

## Deletion/Penghapusan

- Hapus semua records/baris data yang mengandung missing values
- Hapus semua kolom yang mengandung missing values
- **Hati-hati!** Menghapus terlalu banyak baris/kolom yang mengandung missing values tanpa alasan yang kuat dapat mengakibatkan **information loss**

## Imputation/Pengisian Nilai

- Mengganti missing values dengan rata-rata (mean), nilai tengah (median), dan atau modus (mode) untuk atribut numerik
  - Hati-hati terhadap potensi bias
  - Ingat, nilai rata-rata bersifat sensitif terhadap keberadaan outliers
- Mengganti missing values dengan modus atau kategori "missing" untuk atribut **kategorikal**
- Mengganti missing values dengan Teknik Multiple Imputation By Chained Equation (MICE)

# Data Quality Issues: Formatting Errors

Mengidentifikasi kesalahan format pada dataset

Email	Jenis Transaksi	Nominal	Tanggal
riki_akbar_(at)_gmail.com	Pembayaran Kartu Kredit	2,000,000	23/12/2023
<a href="mailto:riki_akbar@gmail.com">riki_akbar@gmail.com</a>	Transaksi Marketplace	587,000	23/12/2023
<a href="mailto:riki_akbar@gmail.com">riki_akbar@gmail.com</a>	Transaksi Marketplace	238,400	23/12/2023
<a href="mailto:riki_akbar@gmail.com">riki_akbar@gmail.com</a>	Transaksi Marketplace	127,882	23/12/2023
<a href="mailto:riki_akbar@gmail.com">riki_akbar@gmail.com</a>	Pembayaran KPR	6,473,122	23/12/2023
<a href="mailto:riki_akbar@gmail.com">riki_akbar@gmail.com</a>	Transaksi Amazon UK	87	2023/12/23

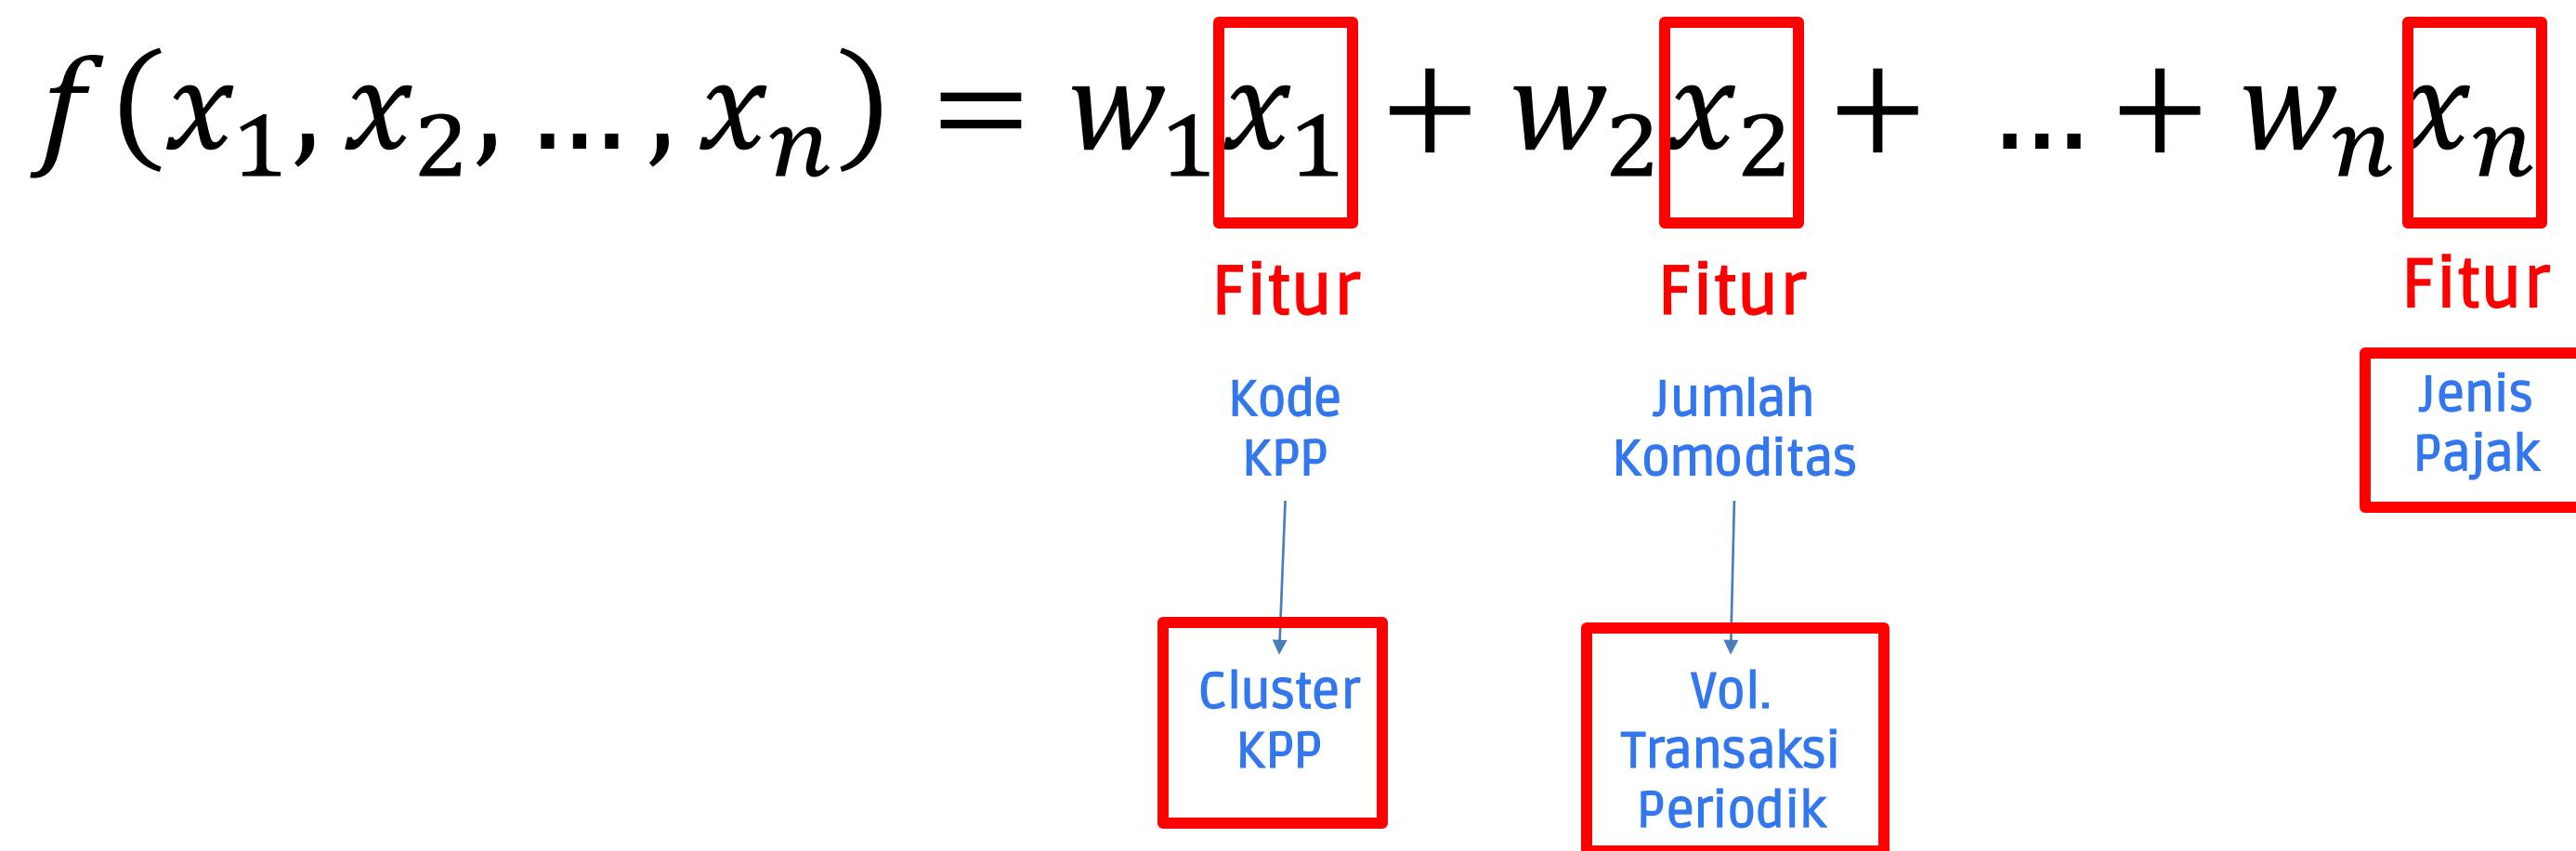
How to handle?

Ubah baris/kolom data yang mengandung kesalahan format berdasarkan standar format yang ditetapkan

Contoh: format tanggal, email, mata uang, dll

# Feature Engineering

Misal, kita akan membuat sebuah model prediktif yang memprediksi penerimaan pajak komoditas tertentu



Pada beberapa kasus kita perlu mentransformasi fitur yang ada menjadi fitur baru yang lebih *useful*

# Transformasi Data Numerik: Scaling & Standardisation

Tujuan: mengubah nilai pada atribut/kolom tertentu menjadi nilai baru dalam skala yang sama

## Scaling

Mengubah interval nilai pada atribut/kolom tetapi menjaga agar distribusi nilai pada atribut/kolom tersebut tetap sama

## Standardization

Mengubah interval nilai pada atribut/kolom sehingga standar deviasi pada distribusi tersebut bernilai 1

### Data Awal

```
2 np.array(df[['budget']])[:5]
array([[1200000],
       [1600000],
       [ 270000],
       [1400000],
       [1200000]])
```

```
1 MinMaxScaler().fit_transform(df[['budget']])[:5]
array([[0.03369158],
       [0.04492772],
       [0.00756754],
       [0.03930965],
       [0.03369158]])
```

*Scale down* sehingga interval nilainya menjadi antara 0 dan 1

```
1 StandardScaler().fit_transform(df[['budget']])[:5]
array([[-0.5826946 ],
       [-0.48678786],
       [-0.80567777],
       [-0.53474123],
       [-0.5826946 ]])
```

$(1.0, 8.484092367284778e-17)$

*Scale down* sehingga standar deviasinya bernilai 1

# Transformasi Data Numerik: Scaling & Standardisation

## DISKUSI

1. Kapan menggunakan teknik Scaling/Standardisation?
2. Bagaimana mengaplikasikan Scaling/Standardisation pada Data Uji/Data Baru?

# Transformasi Data Kategorikal: Encoding

*"From Categories to Numbers"*

## Mengapa Encoding Diperlukan?

1. Pada dasarnya, model machine learning adalah model matematis yang hanya dapat memroses representasi numerik dari sebuah data
2. Oleh karena itu, kita perlu mentransformasi seluruh nilai pada atribut/kolom kategorikal menjadi numerik → encoding

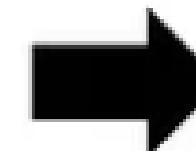
## Teknik-Teknik Encoding

1. One-Hot Encoding
2. Label Encoding

# Encoding: One-Hot Encoding

Original categorical column

Origin
USA
Japan
Europe
USA
Europe



One-Hot encoded columns

Origin_USA	Origin_Japan	Origin_Europe
1	0	0
0	1	0
0	0	1
1	0	0
0	0	1

## Pros

- Cocok untuk memroses kategori nominal

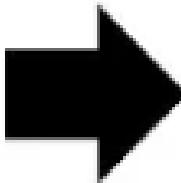
## Cons

- Rentan terhadap **sparsity**
- Untuk kategori yang memiliki kardinalitas tinggi, dapat berujung pada **Curse of Dimensionality**

# Encoding: Label Encoding

Original categorical column

Education
High School
Primary School
Master Degree
Bachelor Degree
High School



Label encoded column

Education
2
1
4
3
2

## Pros

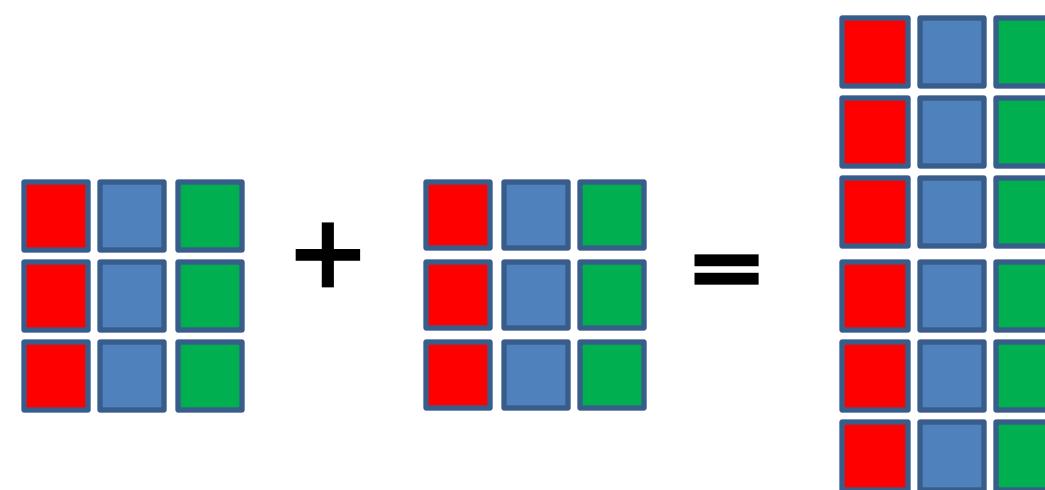
- Cocok untuk memroses kategori ordinal, model dapat mengidentifikasi pola urutan bermakna yang berguna pada saat mengembangkan model prediktif

## Cons

- Apabila label encoding digunakan pada atribut kategori non-ordinal, model akan keliru menginterpretasi bahwa pola urutan pada atribut/kolom tersebut memiliki makna sehingga berujung pada hasil prediksi yang tidak tepat

# Data Enrichment: Concatenation & Merging (Join)

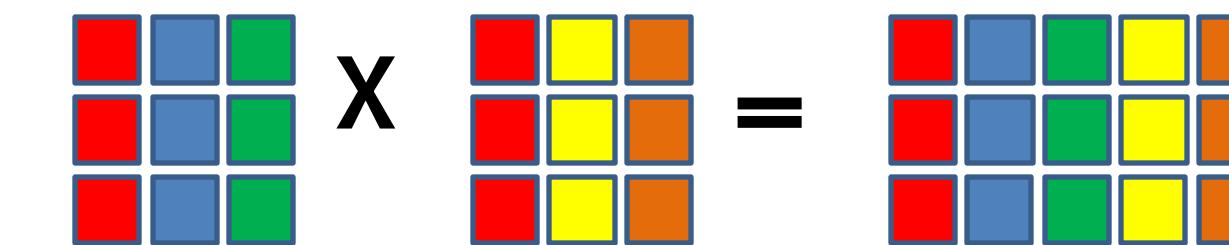
## Concatenation



```
df1 = df.iloc[43:45]
df2 = df.iloc[50:52]
pd.concat([df1, df2])
```

Menambah baris data

## Merging



```
df1 = df[['name','rating','genre','year','director','writer','country']]
df2 = df[['name','rating','genre','year','budget','gross']]
pd.merge(df1, df2,
         how="inner",
         right_on=['name','rating','genre','year'],
         left_on=['name','rating','genre','year'])
```

Menambah kolom data

# Tipe-Tipe Join

All Left,  
Matched-Only Right

**LEFT JOIN**



**INNER JOIN**

All-Matched

**RIGHT JOIN**



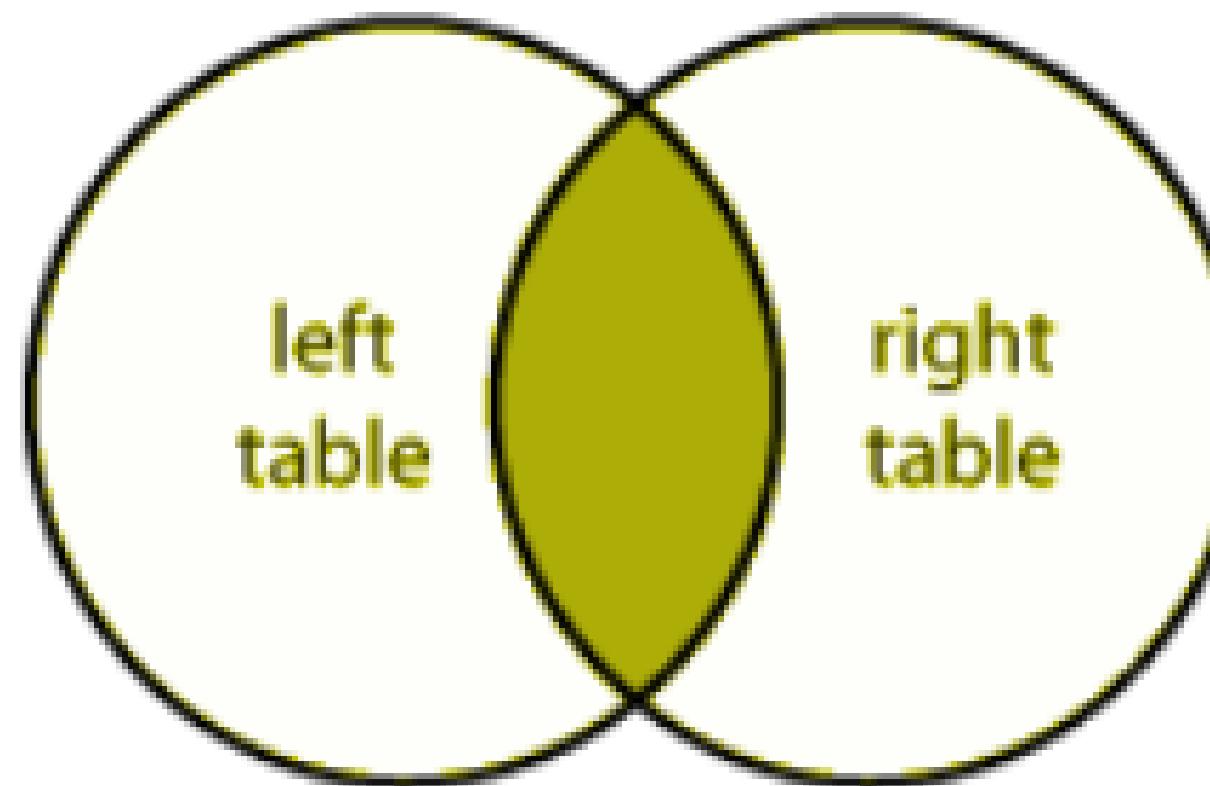
**FULL OUTER JOIN**

All Right,  
Matched-Only Left

All Possible  
Combination

# Tipe-Tipe Join: Inner Join

INNER JOIN



Tabel A		
id	nama	kelas
1	adi	1
2	budi	2
3	charles	1
5	denny	3

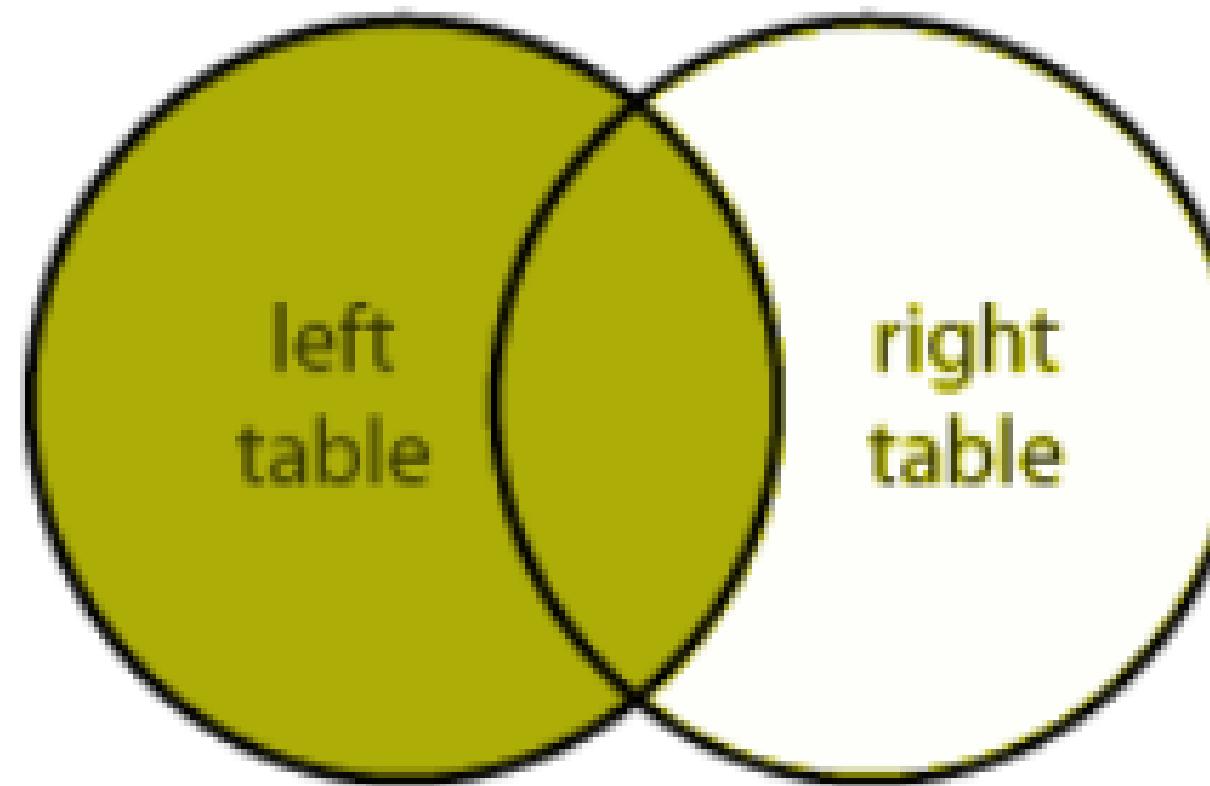
X

Tabel B		
id	nama	kelas
2	budi	2
3	charles	1
5	denny	3
7	gerry	1

id	nama	kelas	nama	kelas
2	budi	2	charles	1
3	charles	1	denny	3
5	denny	3	gerry	1

# Tipe-Tipe Join: Left Join

LEFT JOIN



Tabel A		
id	nama	kelas
1	adi	1
2	budi	2
3	charles	1
5	denny	3

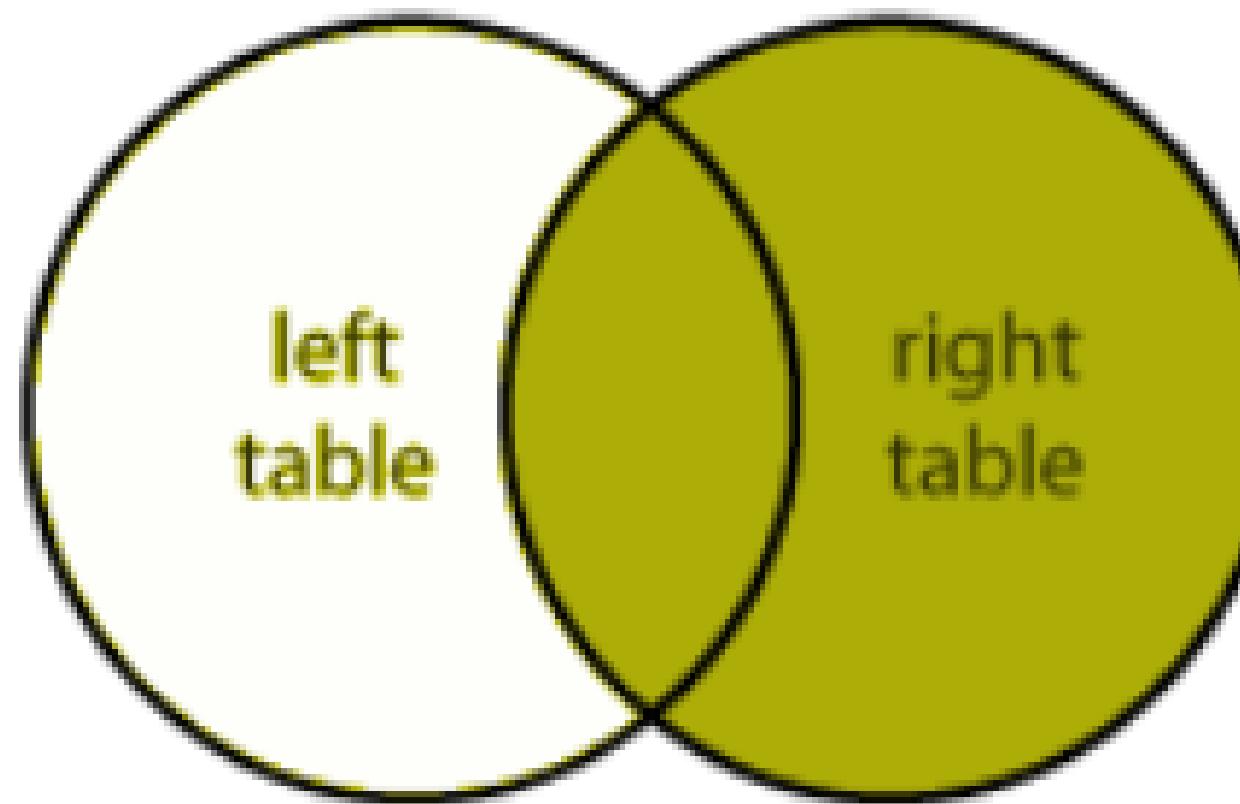
X

Tabel B		
id	nama	kelas
2	budi	2
3	charles	1
5	denny	3
7	gerry	1

id	nama	kelas	nama	kelas
1	adi	1	NULL	NULL
2	budi	2	budi	2
3	charles	1	charles	1
5	denny	3	denny	3

# Tipe-Tipe Join: Right Join

## RIGHT JOIN



Tabel A		
id	nama	kelas
1	adi	1
2	budi	2
3	charles	1
5	denny	3

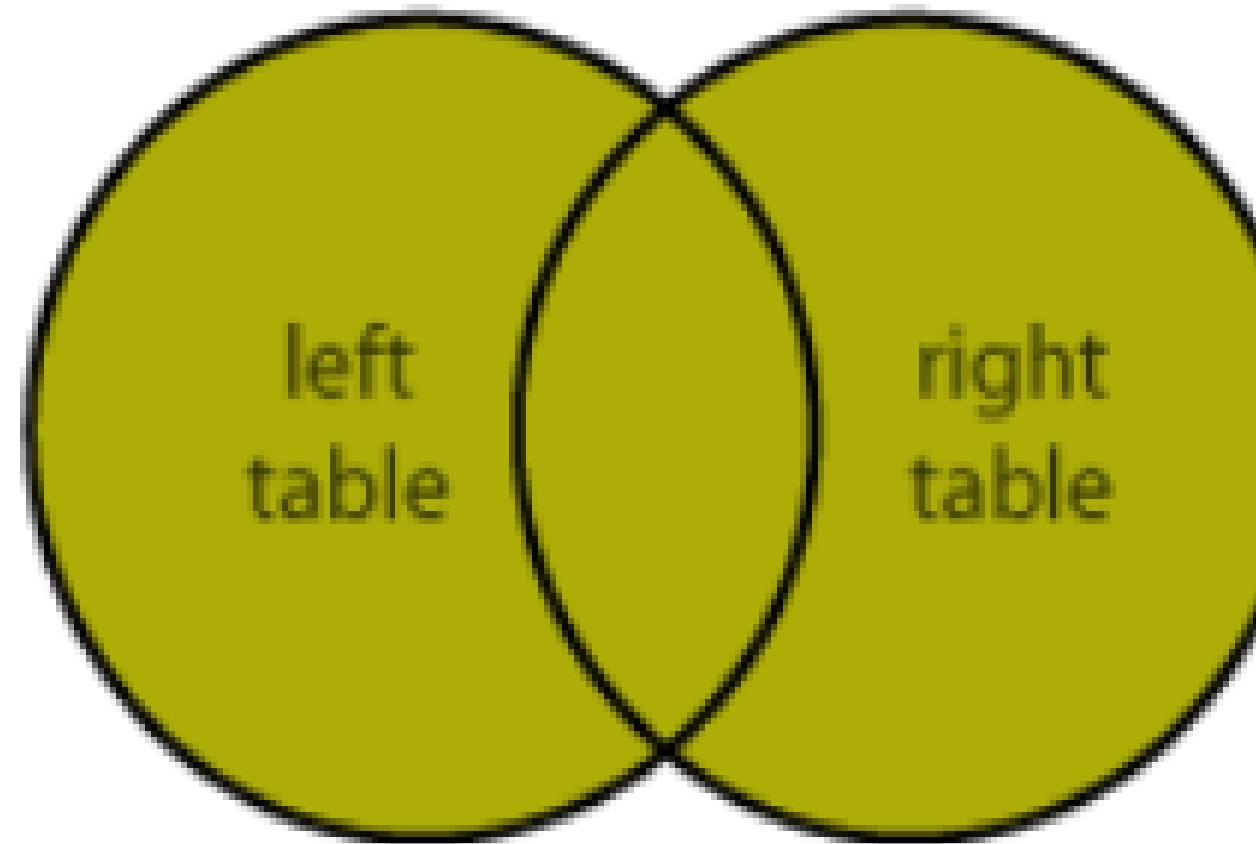
X

Tabel B		
id	nama	kelas
2	budi	2
3	charles	1
5	denny	3
7	gerry	1

id	nama	kelas	nama	kelas
2	budi	2	budi	2
3	charles	1	charles	1
5	denny	3	denny	3
7	NULL	NULL	gerry	1

# Tipe-Tipe Join: Full (Outer) Join

FULL JOIN



Tabel A		
id	nama	kelas
1	adi	1
2	budi	2
3	charles	1
5	denny	3

Tabel B		
id	nama	kelas
2	budi	2
3	charles	1
5	denny	3
7	gerry	1

X

id	nama	kelas	nama	kelas
1	adi	1	NULL	NULL
2	budi	2	budi	2
3	charles	1	charles	1
5	denny	3	denny	3
7	NULL	NULL	gerry	1

# Hands-on Time!

Buka Google Colab

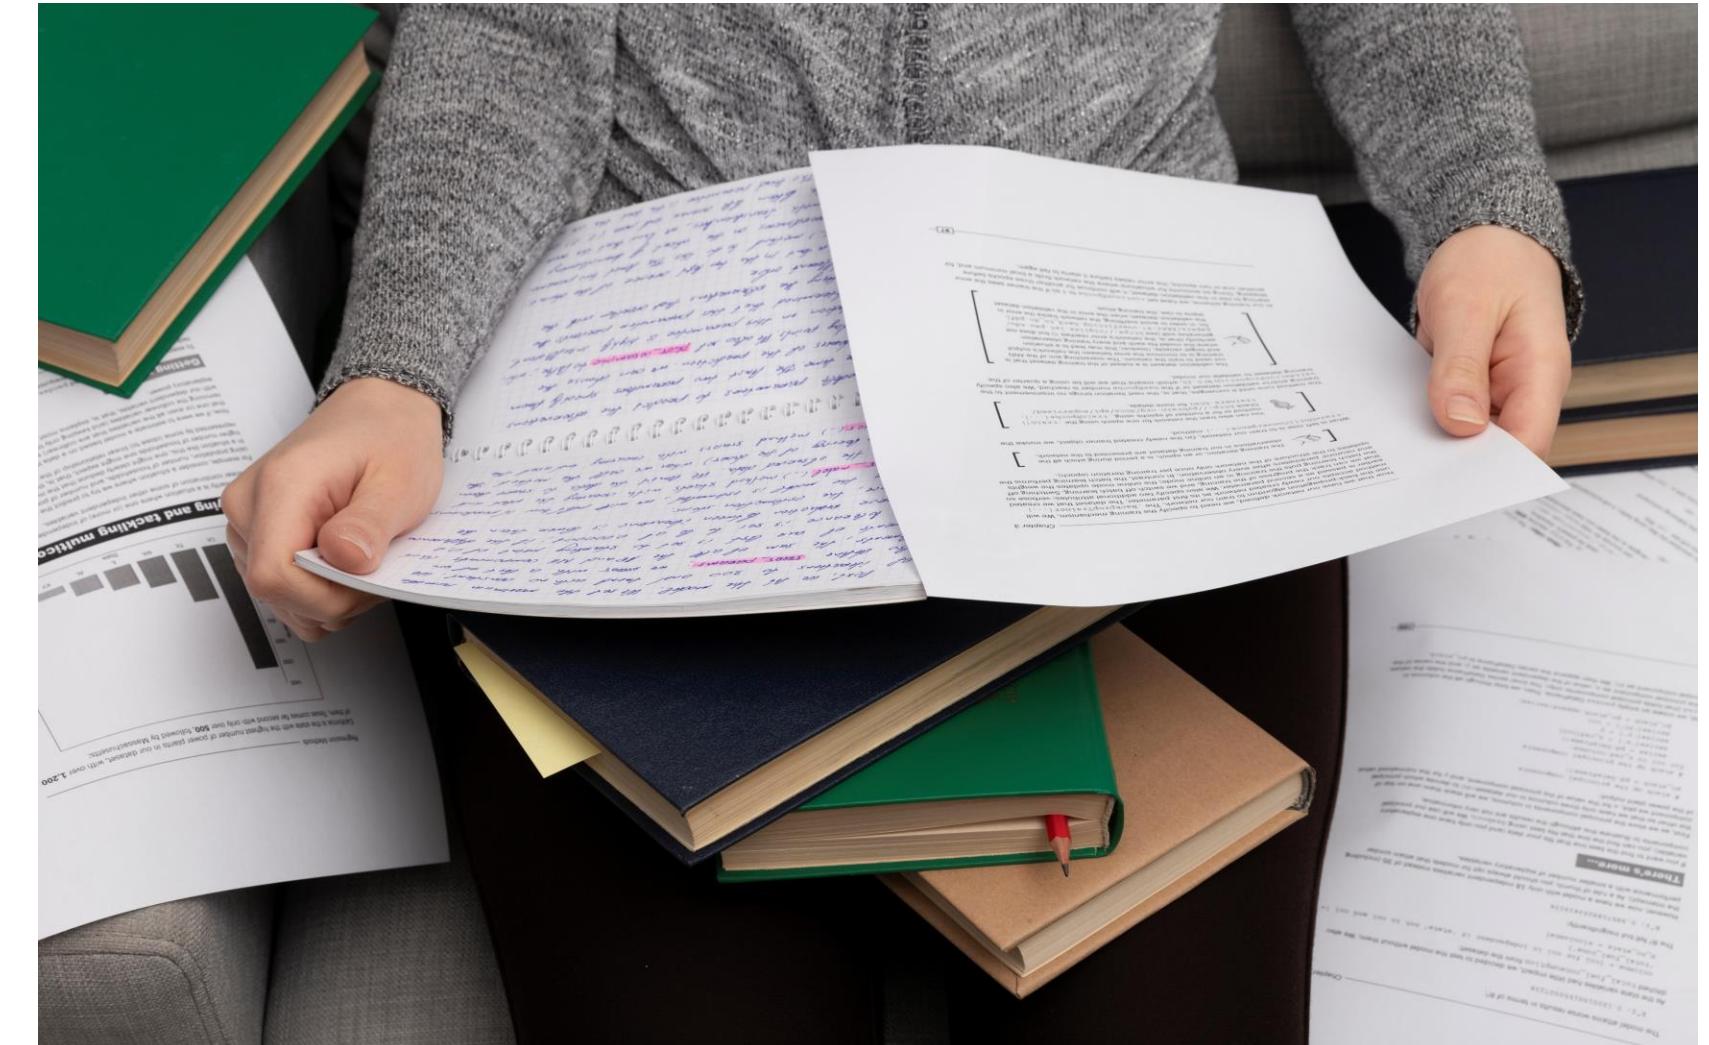


1. Menangani Data Quality Issues
2. Data Transformation
3. Concatenation & Merge (or Join)

# Data Tekstual



Berita



Laporan

# Mengapa Data Tekstual Perlu Data Preparation?

Karena data textual memiliki karakteristik tidak terstruktur (**unstructured**), kompleks (**complex**), dan **noisy**

“

*Saya baru aja pulang dari menginap di Hotel X. Hotel ini benar-benar melebihi ekspektasi sayaaa ! Fasilitasnya gila lengkap memuaskan banget, kamarnya bersih-nyaman, serta pelayanannya sangat ramah. Staf hotel sangat membantu dan selalu siap memenuhi kebutuhan saya*

”

# Mengapa Data Tekstual Perlu Data Preparation?

Karena data textual memiliki karakteristik tidak terstruktur (**unstructured**), kompleks (**complex**), dan **noisy**

“

*slang*

*noise*

*dua token yang berbeda*

*imbuhan*

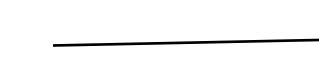
Saya baru **aja** pulang dari menginap di **Hotel** X. Hotel ini benar-benar melebihi ekspektasi **sayaaa !** Fasilitasnya gila lengkap **memuaskan** banget, kamarnya bersih-nyaman, serta pelayanannya sangat ramah. Staf **hotel** sangat membantu dan selalu siap memenuhi kebutuhan saya

”

# Uppercasing, Lowercasing, dan Penghilangan Tanda Baca

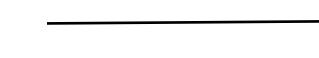
“Fasilitasnya gila lengkap memuaskan banget, kamarnya bersih-nyaman, serta pelayanannya sangat ramah”

**lowercasing**



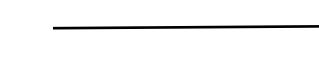
fasilitasnya gila lengkap memuaskan banget, kamarnya bersih-nyaman, serta pelayanannya sangat ramah

**UPPERCASING**



FASILITASNYA GILA LENGKAP MEMUASKAN BANGET, KAMARNYA BERSIH-NYAMAN, SERTA PELAYANANNYA SANGAT RAMAH

**Penghilangan  
Tanda Baca**

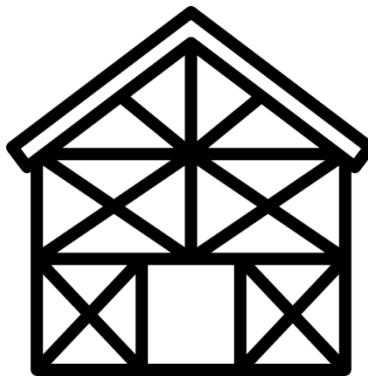


fasilitasnya gila lengkap memuaskan banget kamarnya bersih nyaman serta pelayanannya sangat ramah

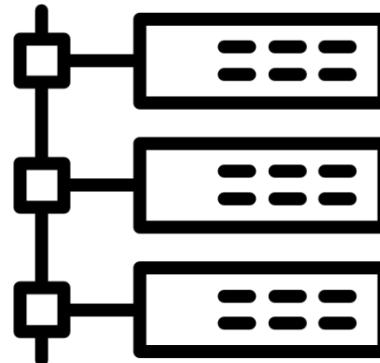
# Tokenisasi

*Memecah teks menjadi unit-unit yang lebih kecil*

## Mengapa Perlu Tokenisasi?



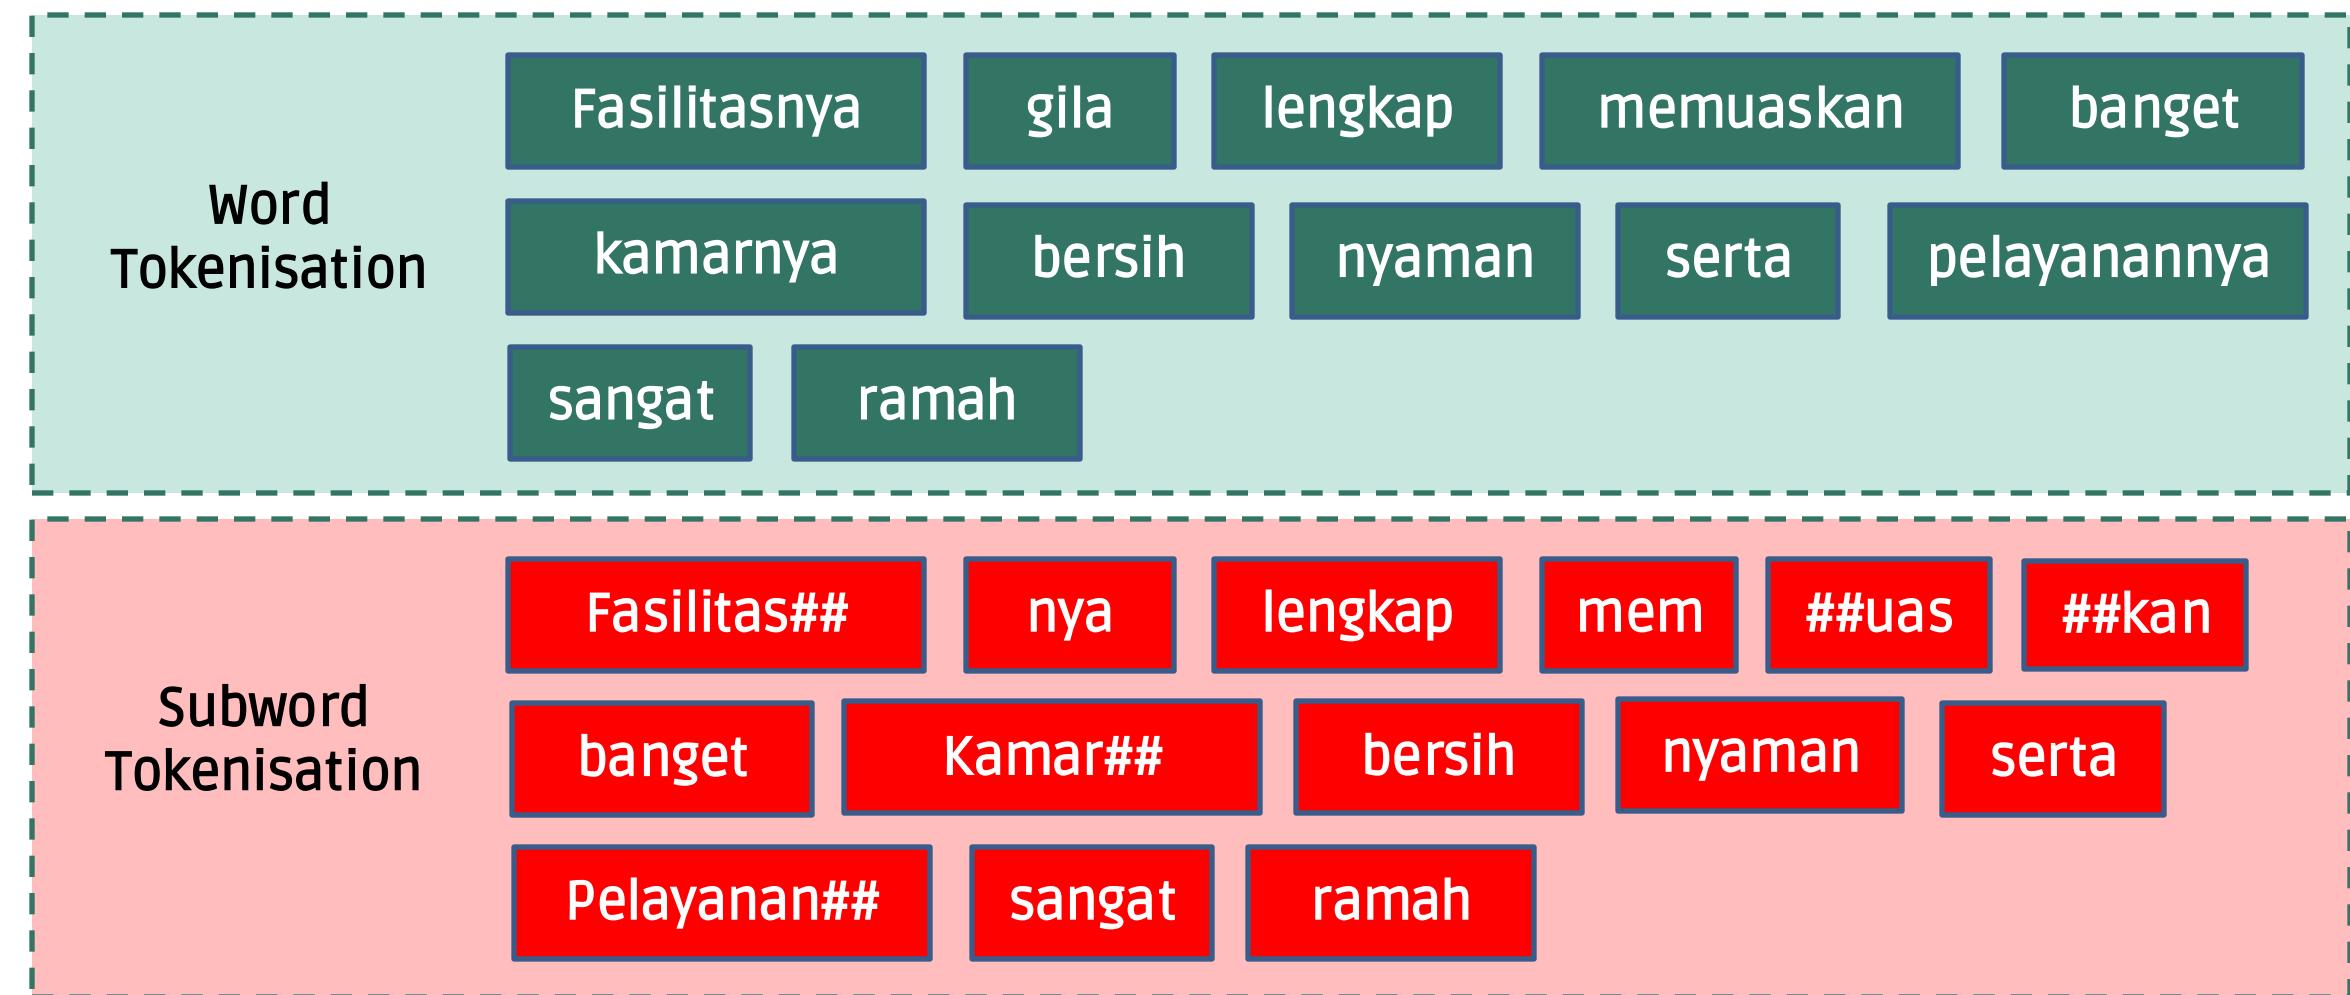
Token menunjukkan struktur teks



Token berperan sebagai fitur dalam pemrosesan teks

## Bagaimana Tokenisasi dilakukan?

“ Fasilitasnya gila lengkap memuaskan banget, kamarnya bersih-nyaman, serta pelayanannya sangat ramah ”



# Stopwords

The 'too frequent' words



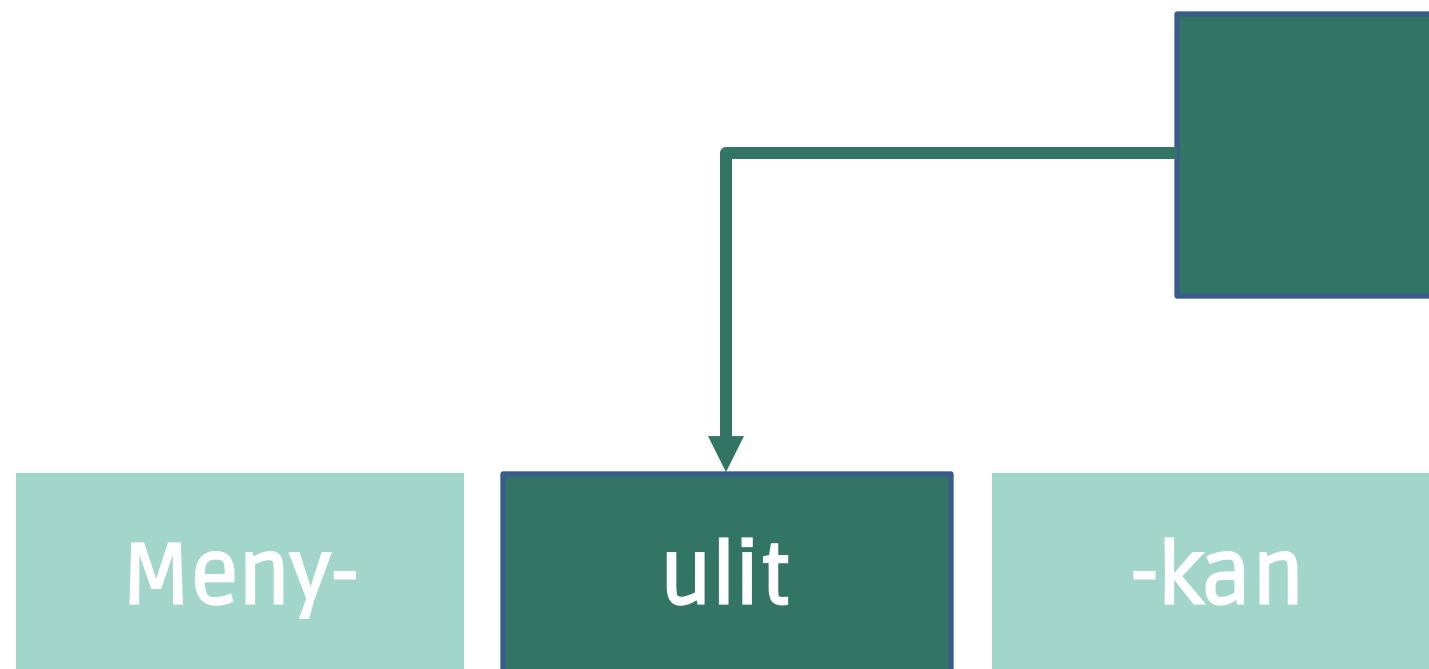
George Kingsley  
Zipf



# Stemming dan Lematisasi

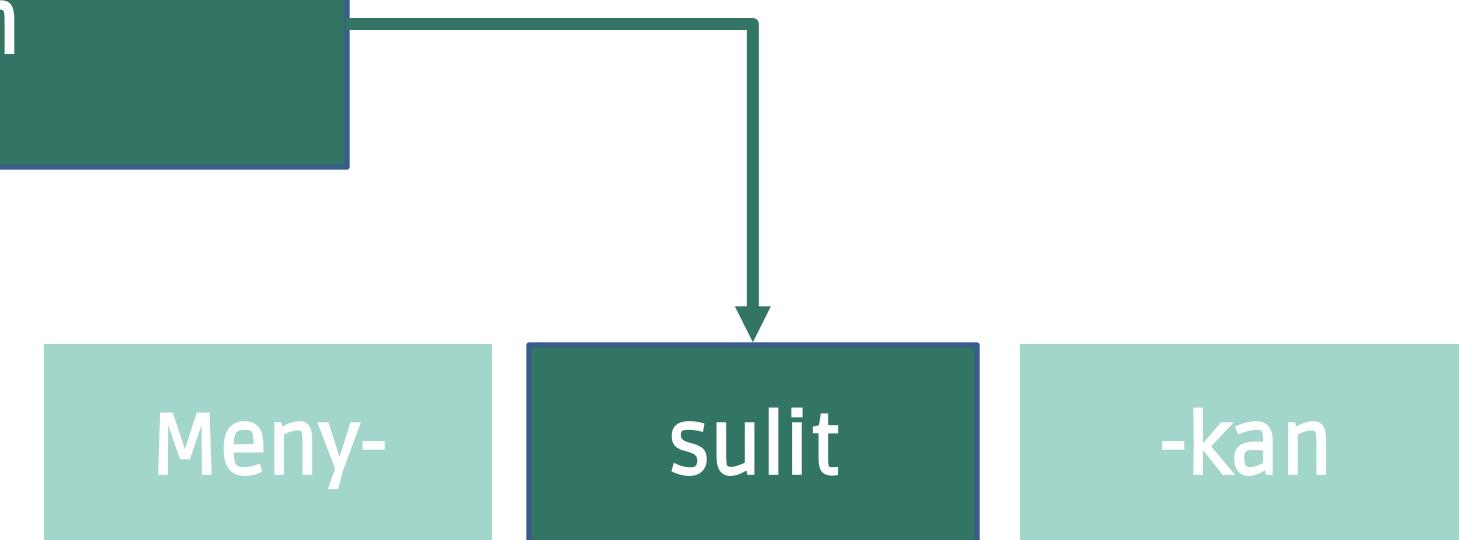
## Stemming

Membuang awalan dan akhiran yang muncul pada sebuah token



## Lemmatisation

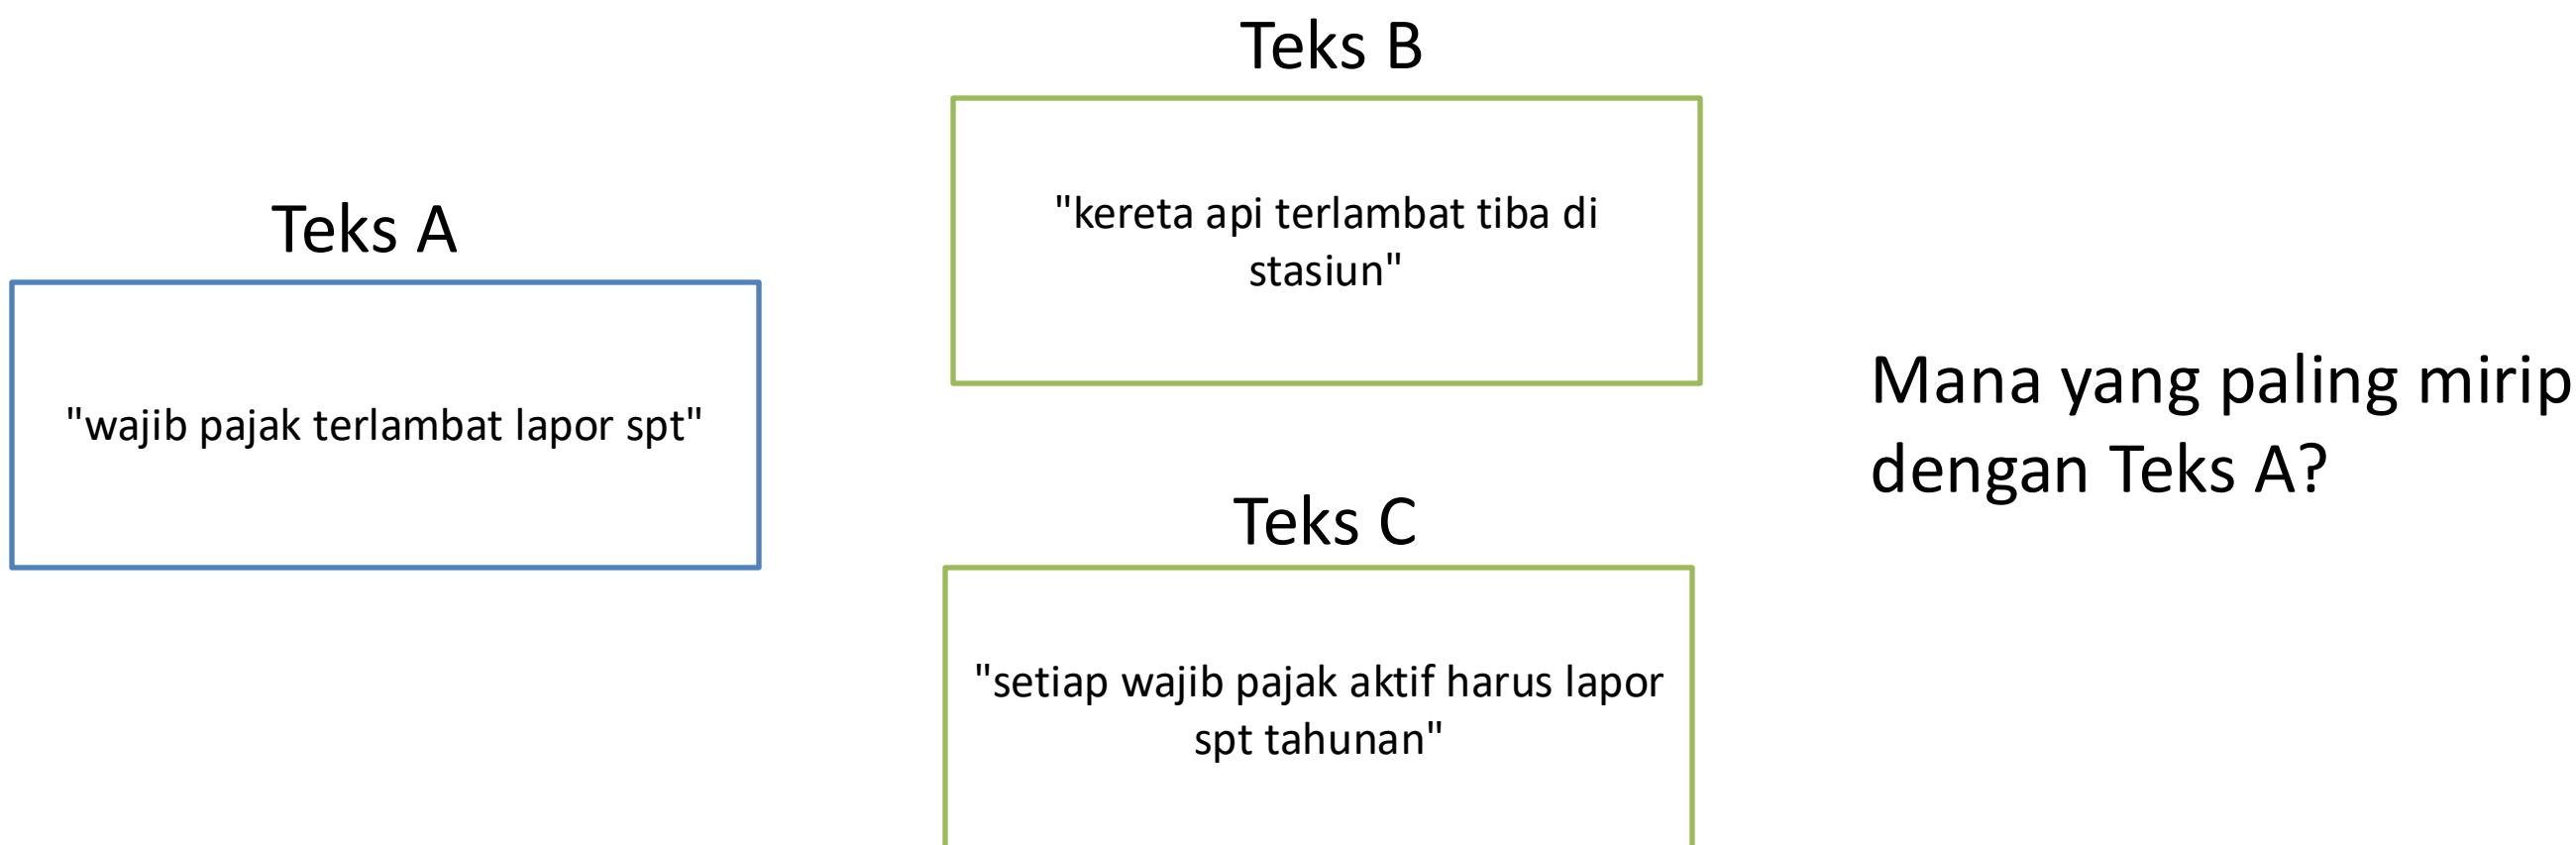
Mengubah token menjadi bentuk dasarnya



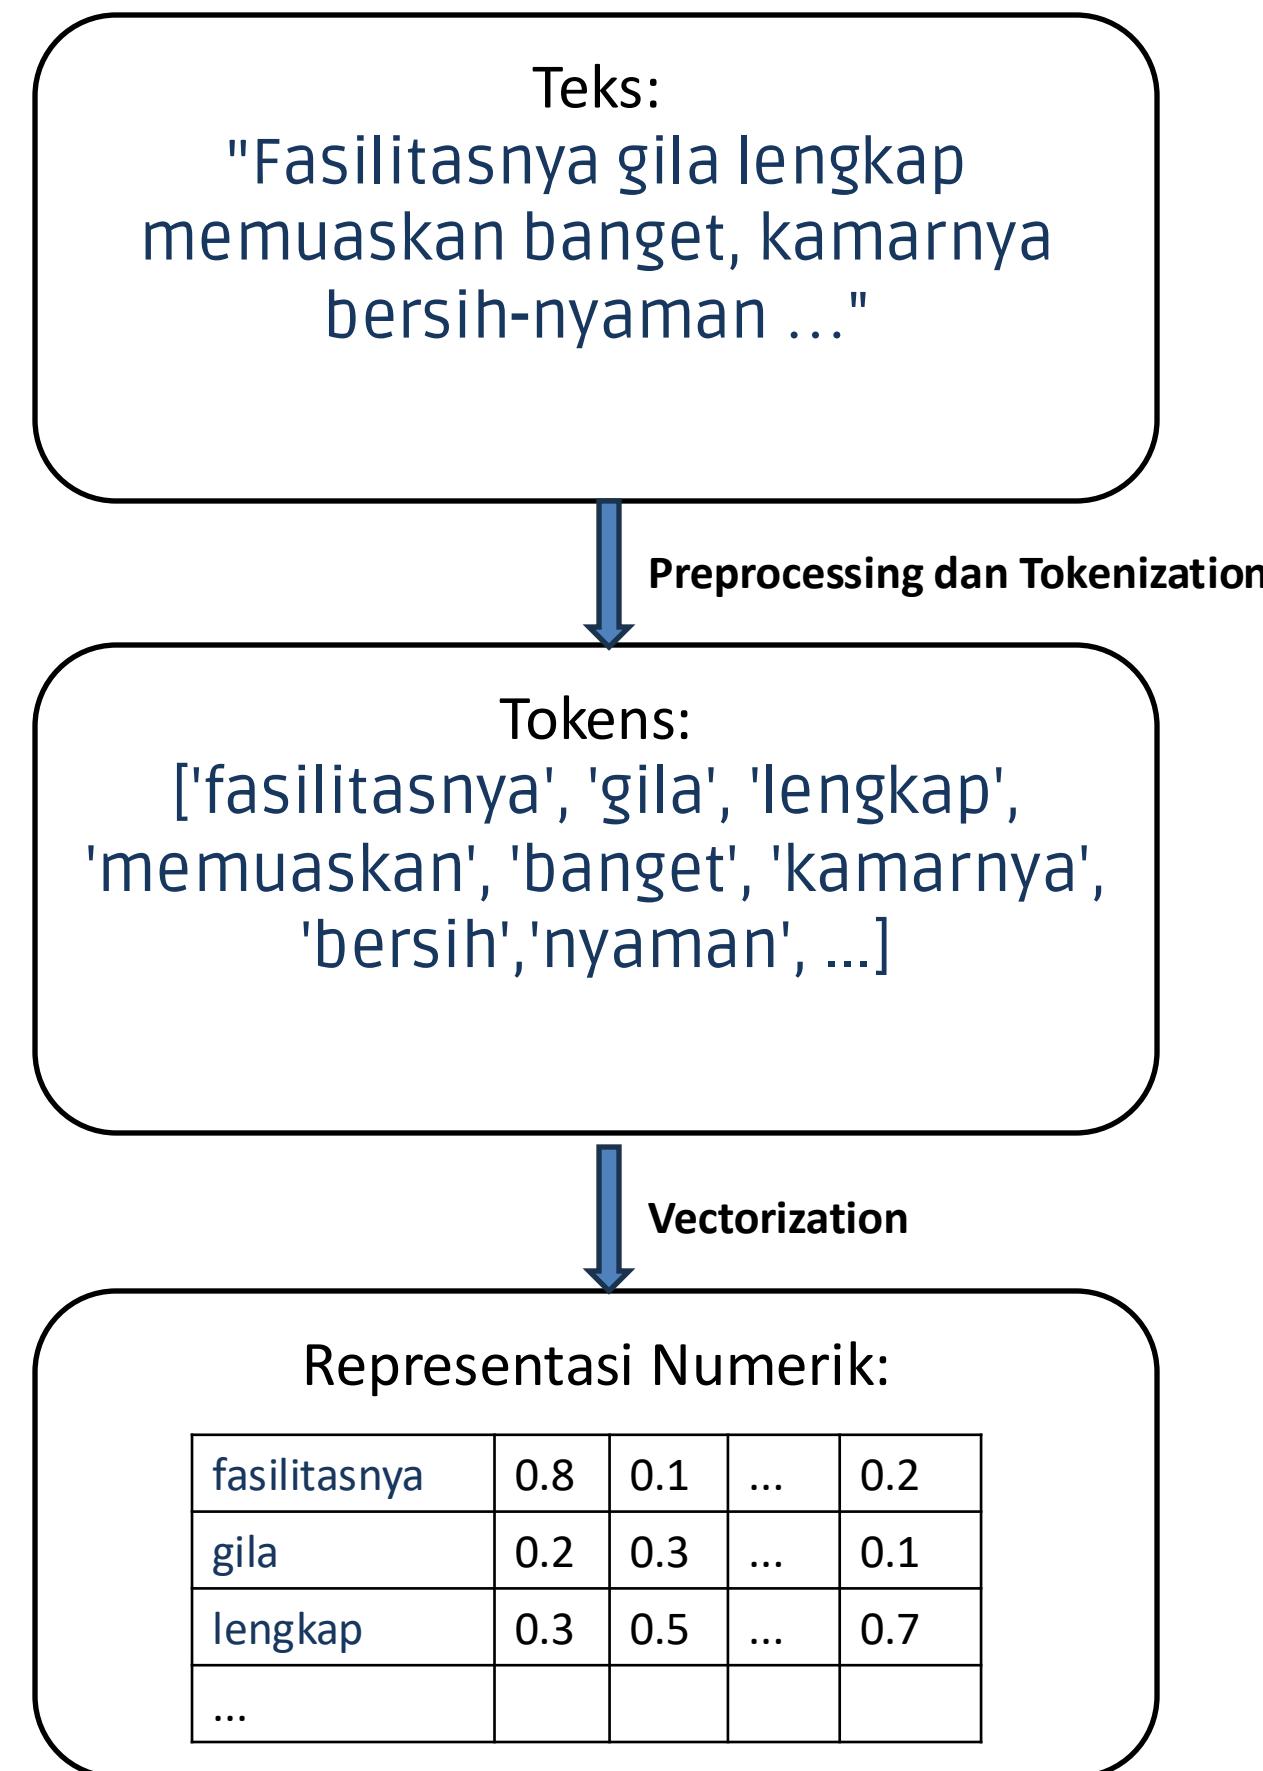
# Text Representation – Why?

Kenapa teks perlu direpresentasikan ke bentuk numerik/angka?

1. Representasi teks adalah jembatan antara bahasa manusia dengan perhitungan matematis yang dilakukan komputer
2. Representasi numerik memungkinkan teks dianalisis dan diukur secara kuantitatif.



# Text Representation



# Text Representation : Bag of Words (BoW)

Setiap cell adalah jumlah kemunculan token/kata pada setiap dokumen

	D1	D2	D3	D4	D5
fasilitasnya	0	1	5	10	8
gila	0	0	14	14	13
lengkap	5	7	0	9	8
memuaskan	12	13	0	5	4
banget	12	5	4	10	12

Representasi numerik untuk dokumen D4 ? [10, 14, 9, 5, 10]

Kelemahan?

- Bias ke token/kata yang umum karena hanya mempertimbangkan frekuensi kemunculan token/kata saja.
- tidak bisa membedakan mana token/kata yang penting dan mana token/kata yang tidak penting.

# Text Representation : TF-IDF

TF-IDF adalah penyempurnaan dari BoW, dimana TF-IDF memberikan nilai kepada kata berdasarkan 2 prinsip:

- **Seberapa sering** kata muncul di dokumen ini (**TF**)
- **Seberapa jarang** kata muncul di seluruh koleksi dokumen lain (**IDF**)

Tujuannya adalah menonjolkan kata yang sering muncul di satu dokumen tertentu, tapi jarang muncul di dokumen lain.

$$W_{t,d} = \text{TF}(t, d) \times \text{IDF}(t)$$

Dimana:

1. **Term Frequency (TF)**: Frekuensi kata dalam dokumen tertentu.

$$\text{TF}(t, d) = \frac{\text{Jumlah kemunculan kata } t \text{ di dokumen } d}{\text{Total kata dalam dokumen } d}$$

2. **Inverse Document Frequency (IDF)**: Mengukur seberapa informatif sebuah kata.

$$\text{IDF}(t) = \log \left( \frac{\text{Total Dokumen (N)}}{\text{Jumlah Dokumen yang mengandung kata } t} \right)$$

# Text Representation : TF-IDF

Misalkan kita memiliki 3 dokumen:

A = "pemilik kendaraan bermotor harus bayar pajak setiap tahun"

B = "pemilik dan pembeli bertemu di kantor notaris "

C = "setiap pemilik npwp harus bayar pajak dan lapor spt"

Kata "**pemilik**" dalam dokumen A

- $\text{TF}(\text{"pemilik"}, \text{dokumen A}) = 1/8 = 0.125$
- $\text{IDF}(\text{"pemilik"}) = \log(3/3) = 0$

$$\text{TF-IDF}(\text{"pemilik}, \text{dokumen A}) = 0.125 \times 0 = 0$$

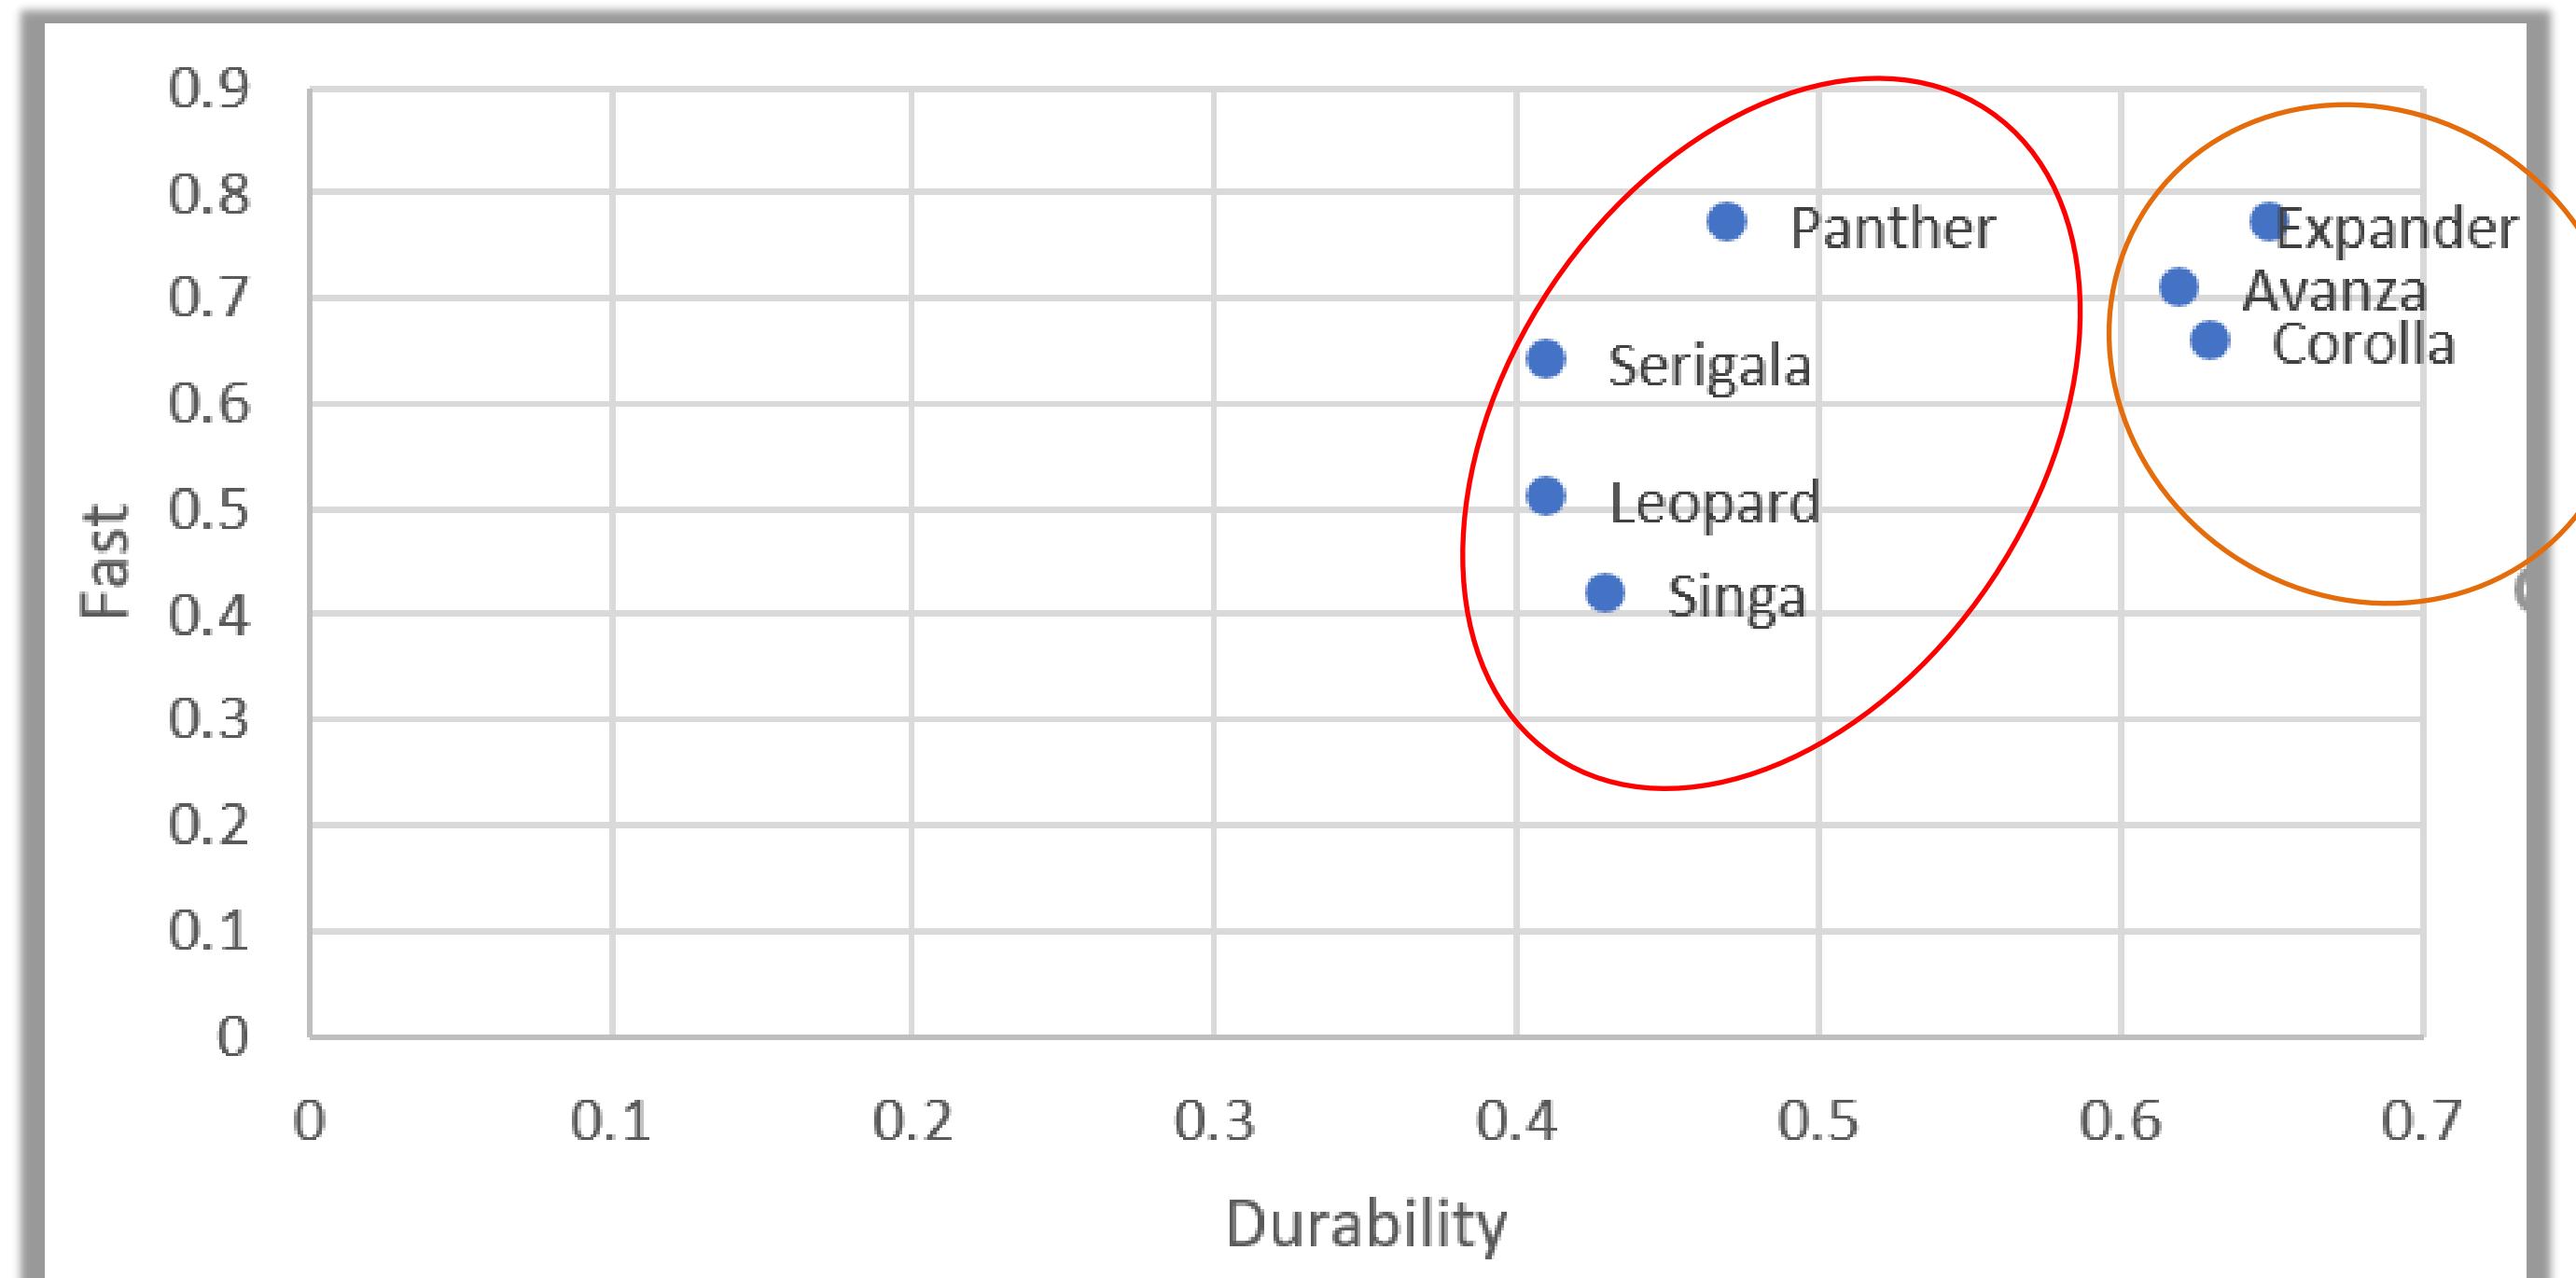
Kata "**notaris**" dalam dokumen B

- $\text{TF}(\text{"notaris"}, \text{dokumen A}) = 1/7 = 0.14$
- $\text{IDF}(\text{"notaris"}) = \log(3/1) = 0.47$

$$\text{TF-IDF}(\text{"notaris}, \text{dokumen B}) = 0.14 \times 0.47 = 0.06$$

# Text Representation: Word Embedding

Mengubah kata menjadi angka



Kata dengan makna yang mirip seharusnya berada pada koordinat yang berdekatan pada semantic space

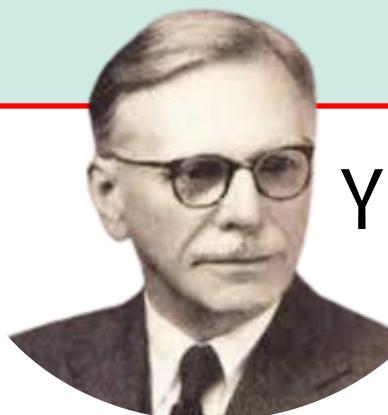
# Text Representation: Sentence Embedding

## What's the problem with word embedding?

Rudi bersimpati kepada Adi yang tidak lulus ujian matematika

VS.

Adi bersimpati kepada Rudi yang tidak lulus ujian matematika



You shall know a word by the company it keeps  
(John Rupert Firth, British Linguist)

## Hence, Sentence Embedding

Rudi bersimpati kepada Adi yang tidak lulus ujian matematika



[0.35 0.49 0.88 -1.3 0.36 0.17 0.88]

Adi bersimpati kepada Rudi yang tidak lulus ujian matematika



[0.85 0.77 0.21 -1.5 0.41 0.77 0.29]

# Hands-on Time!

Buka Google Colab

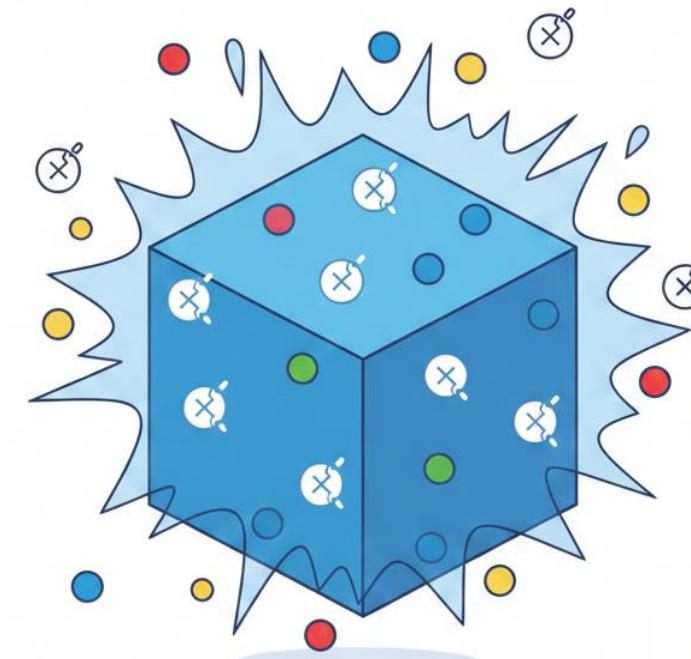


Transformasi Data Tekstual

# Data Quality Issues : Jenis Missing Values

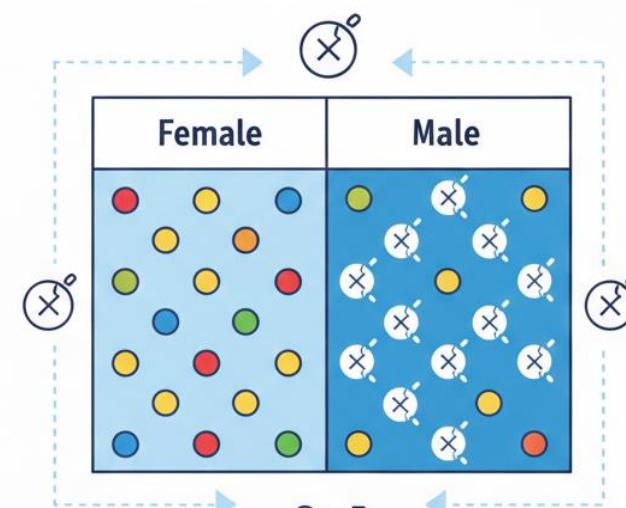
# MISSING COMPLETELY AT RANDOM (MCAR)

## Data loss with no hidden pattern



# MISSING AT RANDOM (MAR)

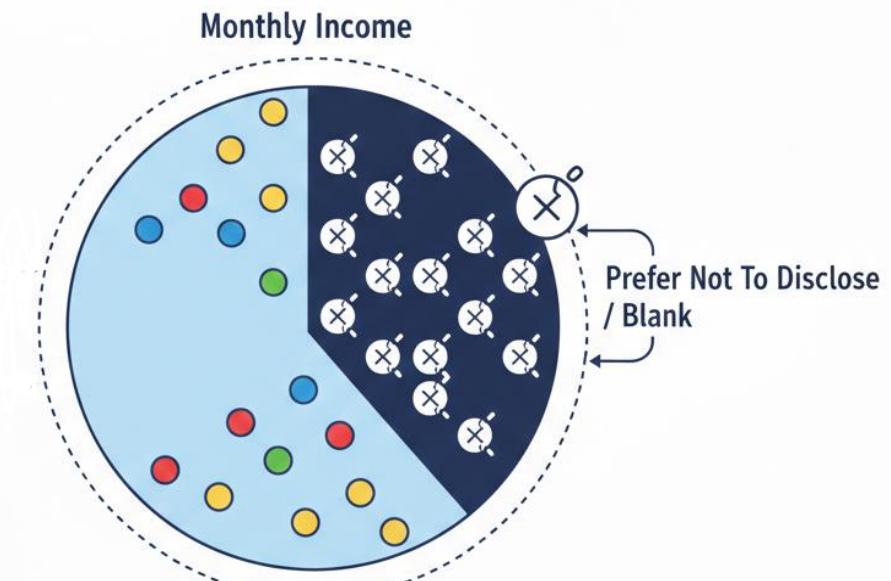
## Data loss related to known variables



**Example:** Men are less likely to report weight in a health survey

# MISSING NOT AT RANDOM (MNAR)

## Data loss related to the missing value itself



Data hilang secara acak, bisa karena ketidaksengajaan misalnya karena sistem error

Data hilang karena dipengaruhi karakteristik atau perilaku dari variabel lain atau kelompok tertentu.

Data hilang karena nilai tersebut cenderung ingin disembunyikan atau sengaja untuk tidak diisi.

# Data Quality Issues : Jenis Missing Values

## Complete Data

Complete data	
Age	IQ score
25	133
26	121
29	91
51	116
54	97
31	98
44	118
46	93
48	141
51	104
30	105
30	110

VS

## MCAR

Incomplete data	
Age	IQ score
25	
26	121
29	91
30	
30	110
31	
44	118
46	93
48	
51	
51	116
54	

## MAR

Incomplete data	
Age	IQ score
25	
26	
29	
30	
30	
31	
44	118
46	93
48	141
51	104
51	116
54	97

## MNAR

Incomplete data	
Age	IQ score
25	133
26	121
29	
30	
30	110
31	
44	118
46	
48	141
51	
51	116
54	

- Missing values benar-benar muncul secara acak
- Biasanya diindikasikan dengan frekuensi kemunculan missing values yang relatif rendah

- Terindikasi ada hubungan antara missing values dengan atribut lain yang ada pada data

- Dipastikan ada hubungan antara missing values dan non-missing values pada atribut yang sama
- Biasanya diindikasikan dengan frekuensi kemunculan missing values yang tinggi (lebih tinggi jika dibandingkan dengan MAR)

# Data Quality Issues : Jenis Missing Values

## Diskusi

Sebuah bank digital memiliki dataset berisi nasabah yang mengajukan pinjaman. Ditemukan tiga kolom dengan *missing values* sebagai berikut:

1. Kolom "**Pekerjaan**": Banyak data kosong karena ada **bug pada aplikasi** versi Android yang menyebabkan menu *dropdown* pekerjaan tidak muncul, sehingga nasabah tidak bisa mengisinya. Pengguna iPhone tidak mengalami masalah ini.
2. Kolom "**Pendapatan Tahunan**": Nasabah yang memiliki **skor kredit rendah** (berdasarkan pengecekan BI Checking/OJK) cenderung tidak mengisi kolom ini karena mereka merasa jika mereka jujur, pinjaman mereka akan ditolak.
3. Kolom "**Tujuan Pinjaman**": Data kosong ditemukan secara acak pada berbagai nasabah tanpa pola tertentu. Setelah dicek, ternyata ini terjadi karena **gangguan server** selama 5 menit yang menyebabkan beberapa data transaksi tidak tersimpan sempurna.

# Data Quality Issues : Key Takeaways

1. Data duplikat ditentukan oleh defenisi entitas dan konteks bisnis, bukan hanya karena baris data terlihat sama,
2. Nilai ekstrem tidak selalu salah, bisa merupakan *noise* atau justru outlier yang penting, tergantung tujuan analisis,
3. Data kosong/*Missing Values* tidak selalu berarti datanya hilang, bagaimana dan alasan kenapa data bisa hilang sangat menentukan *treatment* dan cara menyikapinya.
4. Kesalahan format data bukan berarti datanya salah, tetapi representasi datanya tidak standar sehingga perlu dilakukan perbaikan.

# Hati-hati: Data Leakage!

Menggunakan informasi dari masa depan untuk memprediksi masa depan (a.k.a *cheating*)

## Target/Feature Leakage

Menggunakan fitur yang berkorelasi tinggi dengan kelas target untuk memprediksi target

Contoh:

1. Prediksi Putusan Pengadilan Pajak atas Upaya Banding WP menggunakan amar putusan sebagai salah satu fitur
2. Prediksi churn-rate dari pelanggan komunikasi pascabayar dengan menggunakan fitur "jumlah\_hari\_setelah\_kontrak\_berakhir"

## Train-Test Leakage

Melakukan preprocessing atau melatih model dengan menggunakan data populasi (data train + data test)

Contoh:

Melakukan scaling atribut numerik dengan berdasarkan distribusi data keseluruhan;

## Temporal Leakage

Melatih model *time-series* menggunakan interval waktu yang lebih Panjang tetapi menguji model pada interval waktu yang merupakan subset dari interval waktu yang digunakan pada pelatihan

Contoh:

Training model pada interval Jan-Des tetapi menguji model pada data bulan Juni dalam rentang tahun yang sama

# Large Scale Data Preparation: Chunking in Pandas

## Tanpa Chunking

```
1 import pandas as pd
2 import time
3
4 start_time = time.time()
5 df = pd.read_csv(data_path)
6 end_time = time.time()
7 elapsed = end_time - start_time
8
9 print(f"Size data: {len(df)}")
10 print(f"Waktu: {round(elapsed,3)} detik")
```

```
Size data: 4565000
Waktu: 3.947 detik
```

## Dengan Chunking

```
1 start_time = time.time()
2 total = 0
3
4 for chunk in pd.read_csv(data_path, chunksize=100000):
5     total += len(chunk)
6     pass
7
8 end_time = time.time()
9 elapsed = end_time - start_time
10
11 print(f"Size data: {total}")
12 print(f"Waktu: {round(elapsed,3)} detik")
```

```
... Size data: 4565000
      Waktu: 3.726 detik
```

```
1 start_time = time.time()
2 total = 0
3
4 for chunk in pd.read_csv(data_path, chunksize=500000):
5     total += len(chunk)
6     pass
7
8 end_time = time.time()
9 elapsed = end_time - start_time
10
11 print(f"Size data: {total}")
12 print(f"Waktu: {round(elapsed,3)} detik")
```

```
... Size data: 4565000
      Waktu: 2.877 detik
```

```
1 start_time = time.time()
2 total = 0
3
4 for chunk in pd.read_csv(data_path, chunksize=1000000):
5     total += len(chunk)
6     pass
7
8 end_time = time.time()
9 elapsed = end_time - start_time
10
11 print(f"Size data: {total}")
12 print(f"Waktu: {round(elapsed,3)} detik")
```

```
... Size data: 4565000
      Waktu: 3.518 detik
```

# Large Scale Data Preparation: or Better Yet, Use Polars

## Pandas

```
1 import pandas as pd
2 import time
3
4 start_time = time.time()
5 df = pd.read_csv(data_path)
6 end_time = time.time()
7 elapsed = end_time - start_time
8
9 print(f"Size data: {len(df)}")
10 print(f"Waktu: {round(elapsed,3)} detik")
```

```
Size data: 4565000
Waktu: 3.947 detik
```

## Polars

```
1 import polars as pl
2
3 start_time = time.time()
4 df = pl.read_csv(data_path)
5 end_time = time.time()
6 elapsed = end_time - start_time
7
8 print(f"Size data: {len(df)}")
9 print(f"Waktu: {round(elapsed,3)} detik")
```

```
Size data: 4565000
Waktu: 1.164 detik
```

# Latihan!

Buka Google Colab



# Pandas: Revisited

## Series (one-dimensional)

```
1 df['total_bedrooms']  
  
0      1283.0  
1      1901.0  
2      174.0  
3      337.0  
4      326.0  
...  
16995    394.0  
16996    528.0  
16997    531.0  
16998    552.0  
16999    300.0  
  
Name: total_bedrooms, Length: 17000, dtype: float64
```

## Dataframe (two-dimensional)

```
1 df[['total_bedrooms', 'population', 'median_income']]  
  
total_bedrooms  population  median_income  
0            1283.0       1015.0      1.4936  
1            1901.0       1129.0      1.8200  
2            174.0        333.0      1.6509  
3            337.0        515.0      3.1917  
4            326.0        624.0      1.9250  
...           ...         ...        ...  
16995        394.0       907.0      2.3571  
16996        528.0      1194.0      2.5179  
16997        531.0      1244.0      3.0313  
16998        552.0      1298.0      1.9797  
16999        300.0       806.0      3.0147  
  
17000 rows × 3 columns
```

# Pandas: Revisited

## Access Data by Index

Dataframe  
Name

Row Index

`df.iloc[0:2, 0:2]`

Column Index

	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	households	median_income	median_house_value
0	-114.31	34.19	15.0	5612.0	1283.0	1015.0	472.0	1.4936	66900.0

1

`1 df.iloc[0]`

```
longitude      -114.3100
latitude       34.1900
housing_median_age    15.0000
total_rooms     5612.0000
total_bedrooms  1283.0000
population      1015.0000
households      472.0000
median_income     1.4936
median_house_value 66900.0000
Name: 0, dtype: float64
```

2

`1 df.iloc[0,0:]`

```
longitude      -114.3100
latitude       34.1900
housing_median_age    15.0000
total_rooms     5612.0000
total_bedrooms  1283.0000
population      1015.0000
households      472.0000
median_income     1.4936
median_house_value 66900.0000
Name: 0, dtype: float64
```

3

`1 df.iloc[0:1,0:1]`

```
longitude
0      -114.31
```

4

`1 df.iloc[0,0]`

```
-114.31
```

# Pandas: Revisited

## Access Data by Label

Dataframe  
Name

Row Index/Label

`df.loc['a':'c', 'x':'z']`

Column Label

	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	households	median_income	median_house_value
0	-114.31	34.19	15.0	5612.0	1283.0	1015.0	472.0	1.4936	66900.0

1

```
1 df.loc[0]
```

longitude	-114.3100
latitude	34.1900
housing_median_age	15.0000
total_rooms	5612.0000
total_bedrooms	1283.0000
population	1015.0000
households	472.0000
median_income	1.4936
median_house_value	66900.0000
Name: 0, dtype: float64	

2

```
1 df.loc[0, 'longitude':]
```

longitude	-114.3100
latitude	34.1900
housing_median_age	15.0000
total_rooms	5612.0000
total_bedrooms	1283.0000
population	1015.0000
households	472.0000
median_income	1.4936
median_house_value	66900.0000
Name: 0, dtype: float64	

3

```
1 df.loc[0:1, 'longitude':'latitude']
```

	longitude	latitude
0	-114.31	34.19
1	-114.47	34.40



# Pandas: Revisited

## Filtering

longitude latitude		
119	-115.93	35.55
157	-116.22	36.00
264	-116.57	35.43
568	-117.02	36.40
1863	-117.28	35.13

longitude latitude housing_median_age total_rooms total_bedrooms					
119	-115.93	35.55	18.0	1321.0	
568	-117.02	36.40	19.0	619.0	
2638	-117.67	35.65	18.0	2737.0	
2745	-117.70	35.62	18.0	2657.0	
3054	-117.81	35.65	19.0	1124.0	



Kemenkeu  
Corporate University



# PJJ Data Analytics 2026

## Data Preparation

Cheers!

Riki Akbar  
Ibrahim Saleh Siregar